

分类号：\_\_\_\_\_

密级：\_\_\_\_\_

UDC：\_\_\_\_\_

编号：\_\_\_\_\_

专业硕士学位论文

（工程硕士）

基于数据增强及迁移学习的水声通信信号  
识别技术

硕士研究生：沈泽银

指导教师：殷敬伟 教授

工程领域：船舶与海洋工程

哈尔滨工程大学

2022 年 3 月

分类号：\_\_\_\_\_

密级：\_\_\_\_\_

U D C：\_\_\_\_\_

编号：\_\_\_\_\_

专业硕士学位论文

（工程硕士）

# 基于数据增强及迁移学习的水声通信信号 识别技术

硕 士 研 究 生：沈泽银

指 导 教 师：殷敬伟 教授

学 位 级 别：工程硕士

工 程 领 域：船舶与海洋工程

所 在 学 院：水声工程学院

论文提交日期：2022 年 3 月 6 日

论文答辩日期：2022 年 3 月 11 日

学位授予单位：哈尔滨工程大学

Classified Index:

U.D.C:

A Dissertation for the Professional Degree of Master

(Master of Engineering)

Method of Underwater Acoustic Communication  
Signal Recognition Based on Data Augmentation  
and Transfer Learning

**Candidate:** Shen Zeyin

**Supervisor:** Prof. Yin Jingwei

**Academic Degree Applied for:** Master of Engineering

**Specialty:** Naval Architecture and Ocean Engineering

**Date of Submission:** Mar.6, 2022

**Date of Oral Examination:** Mar.11, 2022

**University:** Harbin Engineering University

## 摘 要

水声通信侦察作为水声通信对抗的重要组成部分,在水下网络中心战中扮演关键角色。水声通信信号识别技术是后续进行相干干扰和破解信息的基础。近年来,以卷积神经网络为代表的深度学习方法在信号调制模式识别领域和水声领域中已取得显著成效。但受到数据量不足的影响,基于卷积神经网络的水声通信信号识别技术无法有效应用于水声通信侦察。因此,本文针对实测水声通信信号,通过生成对抗网络实现数据增强,并通过迁移学习方法提高卷积神经网络的水声通信信号识别准确率。本文的主要研究内容分为以下三个部分:

首先,本文设计了水声通信信号类间识别和类内识别相结合的识别方案,实现 MPSK、OFDM、DSSS 和 MFSK 信号的类间识别以及 MPSK 信号和 MFSK 信号的类内识别。仿真实验结果表明,本文设计的卷积神经网络模型可以实现水声通信信号识别,并且具有良好的抗噪性。松花湖试验结果显示,在数据量充足条件下,本文提出的方案可以实现水声通信信号识别,但在数据量不足条件下,仅有基于循环谱特征的 2DCNN-S 模型可以实现对 2FSK 和 4FSK 信号的识别。

之后,针对水声通信信号数据量不足的情况,本文提出了基于生成对抗网络的水声通信信号数据增强方案,并设计了水声通信信号生成对抗网络(UWACS-GAN),进行了基于数据增强的水声通信信号识别试验研究。试验结果表明,相比采用仿真信号进行数据集的扩充,采用基于 UWACS-GAN 的生成信号进行数据增强表现出更好的识别效果。对于四类信号的识别,采用基于 UWACS-GAN 生成信号数据增强的 1DCNN-DA 模型识别准确率达到 77.13%、2DCNN-DA 模型识别准确率达到 73.17%;对于 MPSK 信号的类内识别,采用基于 UWACS-GAN 生成信号数据增强的 2DCNN-DA 模型识别准确率达到 84.67%。

为进一步提高数据量不足条件下的水声通信信号识别准确率,本文进行了基于迁移学习的水声通信信号识别试验研究。试验结果表明,基于迁移学习的水声通信信号识别技术可以更加有效地提高水声通信信号识别效果,接近数据量充足条件下的识别效果。对于四类信号的识别,采用基于生成信号识别模型迁移的 1DCNN-GTL 模型的识别准确率达到 83.92%、2DCNN-GTL 模型的识别准确率达到 91.42%;对于 MPSK 信号的类内识别,采用基于生成信号识别模型迁移的 2DCNN-GTL 模型的识别准确率达到 86.00%。综合所有研究结果,本文设计的水声通信信号识别方案最终采用基于 UWACS-GAN 生

成信号识别模型迁移的 2DCNN-GTL 模型实现四类水声通信信号类间识别, 采用基于 UWACS-GAN 生成 MPSK 信号识别模型迁移的 2DCNN-GTL 模型实现 MPSK 信号类内识别, 采用基于循环谱特征的 2DCNN-S 模型实现 MFSK 信号类内识别。

**关键词:** 水声通信侦察; 水声通信信号识别; 卷积神经网络; 生成对抗网络; 数据增强; 迁移学习

## ABSTRACT

As an important part of underwater communication countermeasures, underwater acoustic communication reconnaissance plays a key role in underwater network-centric warfare. The underwater acoustic communication signal recognition technology is the basis for subsequent coherent interference and information deciphering. In recent years, deep learning methods represented by Convolutional Neural Networks (CNN) have achieved remarkable results in the field of signal modulation pattern recognition and underwater acoustics. However, due to the lack of data, the underwater acoustic communication signal recognition technology based on CNN cannot be effectively applied to underwater acoustic communication reconnaissance. Therefore, in this paper, aiming at the measured underwater acoustic communication signals, the data augmentation is achieved through the generative adversarial network, and the transfer learning method is used to improve the recognition accuracy of the underwater acoustic communication signal of the convolutional neural network. The main research content of this paper is divided into the following three parts:

First of all, this paper designs a recognition scheme that combines inter-class recognition and intra-class recognition to realize the inter-class recognition of MPSK, OFDM, DSSS and MFSK signals and the intra-class recognition of MPSK signals and MFSK signals. The simulation experiment results show that the CNN model designed in this paper can realize underwater acoustic communication signal recognition and has good noise immunity. The Songhua Lake test results show that under the condition of sufficient data, the scheme proposed in this paper can realize the recognition of the underwater acoustic communication signal, but under the condition of insufficient data, only the 2DCNN-S model based on cyclic spectrum characteristics can realize the recognition of 2FSK and 4FSK signals.

Afterward, in response to the insufficient data of underwater acoustic communication signals, this paper proposes an underwater acoustic communication signal data augmentation scheme based on Generative Adversarial Network (GAN), designs Underwater Communication Signal GAN (UWACS-GAN), and carries out an experimental study of underwater acoustic communication signal recognition technology based on data augmentation. The experimental results show that compared with the use of simulated signals for data set expansion, the use of

generated signals based on UWACS-GAN for data augmentation shows better recognition results. For the inter-class recognition of four modulation patterns of signals, the recognition accuracy of the 1DCNN-DA model based on UWACS-GAN generated signal data augmentation reaches 77.13%, and the recognition accuracy of the 2DCNN-DA model reaches 73.17%; for the intra-class recognition of MPSK signals, the recognition accuracy of the 2DCNN-DA model based on UWACS-GAN generated signal data augmentation reaches 84.67%.

In order to further improve the recognition accuracy of underwater acoustic communication signals under the condition of insufficient data, this paper carries out an experimental study of underwater acoustic communication signal recognition technology based on transfer learning. The experimental results show that the underwater acoustic communication signal recognition technology based on transfer learning can improve the recognition effect more effectively, and close to the recognition effect under the condition of sufficient data. For the inter-class recognition of four modulation patterns of signals, the recognition accuracy of the 1DCNN-GTL model based on the generated signal recognition model transfer reaches 83.92%, and the recognition accuracy of the 2DCNN-GTL model reaches 91.42%; for the intra-class recognition of MPSK signals, the recognition accuracy of 2DCNN-GTL model based on the generated signal recognition model transfer reaches 86.00%. Based on all the research results, the underwater acoustic communication signal recognition scheme designed in this paper finally uses the 2DCNN-GTL model based on the UWACS-GAN generated signal recognition model transfer to realize the inter-class recognition and the intra-class recognition of MPSK signals, and the 2DCNN-S model based on spectral characteristics to realize the intra-class recognition of MFSK signals.

**Key words:** underwater acoustic communication reconnaissance; underwater acoustic communication signal recognition; convolutional neural network; data augmentation; generative adversarial network; transfer learning

# 目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状分析.....	2
1.2.1 水声领域中机器学习研究现状分析.....	2
1.2.2 数据增强技术研究现状分析.....	5
1.2.3 迁移学习技术研究现状分析.....	6
1.3 论文的主要研究内容和结构安排 .....	8
第 2 章 卷积神经网络在水声通信信号识别中的应用分析 .....	11
2.1 水声通信信号识别方案.....	11
2.1.1 水声通信信号特征提取.....	12
2.1.2 水声通信信号识别卷积神经网络模型设计 .....	16
2.1.3 水声通信信号识别效果评价指标.....	18
2.2 基于卷积神经网络的水声通信信号识别仿真实验 .....	20
2.2.1 仿真条件 .....	20
2.2.2 仿真数据集说明 .....	21
2.2.3 水声通信信号类间识别仿真实验结果 .....	22
2.2.4 水声通信信号类内识别仿真实验结果 .....	23
2.3 基于卷积神经网络的水声通信信号识别试验 .....	25
2.3.1 数据量充足条件下的水声通信信号识别试验 .....	25
2.3.2 数据量不足条件下的水声通信信号识别试验 .....	30
2.4 不同条件下卷积神经网络在水声通信信号识别中的应用分析 .....	34
2.5 本章小结.....	35
第 3 章 基于数据增强的水声通信信号识别技术 .....	37
3.1 基于生成对抗网络的水声通信信号数据增强算法研究方案 ....	37
3.2 水声通信信号生成对抗网络模型 .....	38
3.2.1 水声通信信号生成对抗网络模型结构设计 .....	38
3.2.2 水声通信信号生成对抗网络模型损失函数 .....	39
3.2.3 水声通信信号生成对抗网络模型训练过程 .....	40
3.2.4 水声通信信号生成对抗网络模型生成信号分析 .....	40
3.3 水声通信信号数据增强效果评价试验 .....	43
3.3.1 水声通信信号类间识别数据增强效果评价试验 .....	43
3.3.2 水声通信 MPSK 信号类内识别数据增强效果评价试验 ....	48
3.4 本章小结.....	51
第 4 章 基于迁移学习的水声通信信号识别技术 .....	53



4.1 基于卷积神经网络的迁移学习方法及策略 .....	53
4.2 基于卷积神经网络的水声通信信号识别迁移学习方案 .....	54
4.3 基于迁移学习的水声通信信号识别试验 .....	55
4.3.1 基于仿真信号识别模型迁移的水声通信信号识别试验 .....	55
4.3.2 基于生成信号识别模型迁移的水声通信信号识别试验 .....	58
4.4 水声通信信号识别算法综合对比 .....	61
4.4.1 水声通信信号类间识别算法综合对比 .....	62
4.4.2 水声通信 <b>MPSK</b> 信号类内识别算法综合对比.....	64
4.4.3 数据量不足条件下水声通信信号识别方案 .....	65
4.5 本章小结.....	66
结论.....	67
参考文献.....	69

## 第1章 绪论

### 1.1 研究背景及意义

水声通信对抗是水下空间中的信息战和电子战的主要形式之一，旨在削弱、破坏敌方水下通信系统的使用效能和保护己方水下通信系统的效能<sup>[1]</sup>。随着“网络中心战”(Network Centric Warfare, NCW)概念<sup>[2]</sup>的提出，在现代信息化战争中，针对空、天、地、海立体化战场的各类侦察系统、指挥系统和武器系统协同作战模式，敌我双方都需要全面高效的通信联络。目前空、天、地的通信联络和信息传输技术日益成熟，但是水声信道的高复杂性、时变特性和多径效应导致水声通信技术发展缓慢，水声通信对抗亦是如此。水声通信侦察是水声通信对抗的重要组成部分，其系统工作流程图如图 1.1 所示。




图 1.1 水声通信侦察系统的工作流程图

水声通信侦察通过对水声通信信号的截获、检测、识别和参数估计，获取敌方的调制模式、通信频带、通信速率等重要参数，甚至可以破译敌方的通信信息，破解敌方战略意图。

水声通信信号识别技术是水声通信侦察的基础和关键，是获取水下目标信息的重要环节。近年来，以深度学习为代表的水声通信信号调制模式自动识别方法是当下的研究热点。但是水声信道具有受限的可用带宽、显著的多径扩展、快速的信道波动和突发的信道噪声等特征，并且在传输过程中传输距离、可用带宽、噪声和混响会造成水声信号的传输损失且影响接收信号的信噪比<sup>[3]</sup>，导致水声通信信号调制模式识别困难。同时受到海洋环境、出海时间及成本、采集设备等因素的限制，获取大量水声通信信号数据困难，存在水声通信信号数据量不足的问题，导致深度学习方法无法有效应用于水声通信信号调制模式识别中，给水声通信信号调制模式识别带来更进一步的困难和挑战。

通常通过采集相关水域的水下声场环境信息，使用 BELLHOP 等仿真手段，对水声信道进行仿真，获取仿真信号，但是 BELLHOP 仿真得到的物理模型与实际信道存在不

可避免的差异,因此仿真信号无法真正解决数据量不足的问题。针对这个问题,机器学习尤其是数据增强和迁移学习方法给出了新的解决思路。数据增强方法中的生成对抗网络可以通过对实测水声数据进行学习,并不需要实际水下声场环境等信息,就能生成伪实测数据。迁移学习方法只需要源域和目标域具有一定的关联性,就可以通过使用大量源域数据中学到的知识,解决少量数据组成的目标域中的问题。

综上所述,针对水声通信信号数据量不足的问题,本文通过以生成对抗网络为代表的增强方法进行数据生成,并通过迁移学习的方法实现水声通信信号识别具有重要的研究意义。

## 1.2 国内外研究现状分析

### 1.2.1 水声领域中机器学习研究现状分析

#### 1.2.1.1 机器学习在水声领域的研究现状分析

近年来,机器学习(Machine Learning)<sup>[3]</sup>已经从一个模糊的学科发展为一种推动工业和社会发展的力量,并且在多个领域得到应用,其在水声领域也得到了广泛应用。2019年,Binaco等人系统地总结了机器学习的原理及其在声学领域尤其是在水声领域中的应用<sup>[5]</sup>。

在水下声源定位领域,Niu<sup>[6]</sup>等人于2017年将监督学习应用到水下声源定位,使用海试数据验证了所用机器学习算法的定位性能;2018年,Huang<sup>[7]</sup>等人将卷积神经网络运用到仿真声场中的声源定位;2019年,Niu<sup>[8]</sup>等人利用残差卷积神经网络对单水听器数据进行不确定条件下的水下声源目标定位;2020年,Liu<sup>[9]</sup>等人结合了卷积神经网络和多任务学习,与传统匹配场相比具有更好的鲁棒性;同年,Wang<sup>[10]</sup>等人将卷积神经网络和传统波束形成相结合,并采用迁移学习进行声源深度估计,结果证明该方法优于传统卷积神经网络。

在水下目标识别领域,王强<sup>[11]</sup>等人于2015年将卷积神经网络和深度置信网络运用到水下目标分类识别中,但受限于数据量无法发挥其优势;2016年,Kim<sup>[12]</sup>等人将卷积神经网络运用在声纳图像中,实现了对ROV轨迹的跟踪;2017年,Valdenegro-Toro<sup>[13]</sup>等人将深度卷积神经网络运用于水下小目标识别,性能超越了支持向量机等传统机器学习算法;2018年,王昆明<sup>[14]</sup>将迁移学习技术应用到水下目标识别中,在数据量有限的条件下提高了水下目标识别精度;2019年,刘韦伯<sup>[15]</sup>基于YOLOv3模型对五类水下目标声纳图像进行识别;2020年,王升贵<sup>[16]</sup>等人针对水下目标信号的LOFAR谱图,采用卷

积神经网络对七类目标的舰船辐射噪声进行识别；同年，刘有用<sup>[17]</sup>等人使用生成对抗网络对水下图像样本进行扩充，提高了目标识别的准确率。

在地声反演领域，Piccolo<sup>[18]</sup>等人于 2019 年使用机器学习模型从声学信号中提取特征用于预测地声特性，减小了匹配场运算的复杂度；2020 年，Frederick<sup>[19]</sup>等人将卷积神经网络应用在声场沉积物分类中，相比传统匹配场算法效果更好；同年，Smaragdakis<sup>[20]</sup>等人将隐马尔科夫过程与遗传算法提取的地声特征相结合，提出了一种可靠的地声反演算法；同年，Shen<sup>[21]</sup>等人将径向基函数网络运用在地声反演中，相比传统方法对未知的沉积物类别具有更高的灵敏度。

在水声通信信道估计与均衡领域，de Sousa<sup>[22]</sup>等人于 2018 年使用无监督学习代替经典的信道均衡算法与 SOM(Self-Organization Map)方法相结合，在 FPGA 上实现对跟踪和识别时变失真 QAM 符号；2019 年，Jiang<sup>[23]</sup>等人提出基于深度神经网络的信道估计器，相比传统信道估计算法性能更优，且无需信道自相关矩阵和噪声方差的先验估计信息；2021 年，Zhang<sup>[24]</sup>等人提出了一种基于元学习的水声通信 OFDM 系统来解决实际应用中的不匹配问题，相比传统 OFDM 水声通信系统和传统机器学习在各种水声场景下具有更好的误码率和学习能力；同年，Lee-Leon<sup>[25]</sup>等人设计了一种基于深度置信网络的接收器系统，对抗多普勒效应和多径引起的信号失真；同年，Ouyang<sup>[26]</sup>等人将超分辨率神经网络用于 OFDM 水声通信系统中的信道估计，提出了一种性能良好且节省导频的信道超分辨率神经网络(CSRNet)；2022 年，Zhang<sup>[27]</sup>等人提出了一种基于深度学习的 OFDM 水声通信接收器，在准确率和效率方面优于最小二乘估计的传统 OFDM 水声通信系统。

在自适应水声通信领域，Wang<sup>[28]</sup>等人于 2017 年使用强化学习估计和跟踪水声信道模型参数和状态，实现长期点对点水声通信系统的最优发射参数设置；同年，Fu<sup>[29]</sup>等人提出了一种基于强化学习 Dyna-Q 算法的自适应水声通信策略，来预测信道状态和通信吞吐量，与直接反馈有效信噪比方案相比具有更高的通信吞吐量；2019 年，Su<sup>[30]</sup>等人提出了一种基于强化学习的自适应水声通信调制编码方案，实现动态选择水声通信系统的调制和编码策略。

在水声通信网络中，Harb<sup>[31]</sup>等人于 2015 年提出了一种强化型 K-means 算法，协调水声通信网络节点间的数据传输，减少了网络传输的能量损耗；2020 年，Park<sup>[32]</sup>等人提出了一种 UW-ALOHA-Q 的介质访问控制方法，将 Q-learning 与 ALOHA 协议结合以有效使用水声信道。

### 1.2.1.2 机器学习在水声通信信号识别领域的研究现状分析

如今水声通信信号调制模式复杂、种类繁多,且存在多模式并存的情况,人工识别困难,因此水声通信信号自动识别成为研究热点。水声通信主要采用多进制频移键控信号(MFSK)、多进制相移键控信号(MPSK)、直接扩频调制信号(DSSS)和正交频分复用信号(OFDM)四类调制模式信号<sup>[33]</sup>。其中,MFSK 信号的抗噪性和抗衰减性能较好,但通信速率慢;MPSK 信号具有一定的抗多普勒频移能力,信号峰均比高,带宽利用率高;OFDM 信号频带利用率高,具有良好的抗多途扩展性能,能有效对抗多径造成的符号间干扰,系统传输信息容量大,频谱利用率高,但是峰均功率比高,对频率偏移和载波相位敏感;DSSS 信号具有抗干扰能力强、低截获率、多址能力和时间分辨率高等优势,主要应用在远程水声通信、隐蔽水声通信、高质量水声通信和码分多址水声通信中<sup>[34]</sup>。

目前,水声通信信号自动识别方法主要分为基于判决理论的似然假设检验方法(Likelihood Based, LB)和基于特征提取的信号识别方法(Feature Based, FB)<sup>[35]</sup>。LB 方法判决规则简单,但是统计计算复杂度高,需要载频、码率等先验知识,且稳健性较差。相比之下,FB 方法不仅不需要先验信息,而且具有较低的计算复杂度,以及良好的环境适应性,因此广泛应用于实际中。FB 方法主要通过特定的信号处理方法从原始信号中提取出可以用于识别的特征量,例如小波变换特征<sup>[36]</sup>、循环谱特征<sup>[37]</sup>等,然后输入到分类器中进行判决,最终输出识别的类型。对于水声通信信号识别而言,无法获得先验信息,因此基于特征提取的信号识别方法显然更加适用。

近年来,机器学习逐渐应用于水声通信信号识别领域,已研究出多种有效的识别方法。2015 年,江伟华<sup>[38]</sup>等人设计了一种基于信号功率谱、平方谱构建的无需先验知识的特征向量的最小二乘支持向量机分类器,实现了 BPSK、QPSK、MFSK 三类水声常用通信信号的识别;2016 年,葛轶洲<sup>[39]</sup>等人提出了一种基于广义循环累积量的支持向量机算法,实现了在 Alpha 稳定分布噪声下的水声通信信号识别;2018 年,Ding Li-Da<sup>[40]</sup>等人提出了一种结合卷积神经网络和长短时记忆网络的 CNN-LSTM 模型,实现了在 Alpha 稳定脉冲噪声和多普勒频移的多径衰落水声信道环境下的水声通信信号识别;2019 年,邵梦琦<sup>[41]</sup>将多种机器学习算法应用于非合作水声通信信号识别,实现了对单载波信号、直接扩频序列信号和正交频分复用信号的识别;同年,Yu<sup>[42]</sup>等人提出了一种基于瞬时特征的长短时记忆网络模型,实现了对 BPSK、QPSK、8PSK、OFDM 和 DSSS 信号的识别。传统机器学习算法对于数据量的要求较大,而水声试验数据获取困难,因此很多传统机器学习算法在水声领域的研究基本是基于仿真数据展开,其算法模型是否能在实际

水声通信信号识别领域应用是亟需解决的问题。

本文拟研究基于水声通信信号时序信号、时频特征和循环谱特征的水声通信信号识别技术,采用卷积神经网络进行对四类常用水声通信信号进行类间识别,以及对 MPSK 信号和 MFSK 信号的类内识别。

### 1.2.2 数据增强技术研究现状分析

数据增强(Data Augmentation, DA)技术<sup>[43]</sup>是为了解决机器学习模型缺乏高质量且标注完善的训练数据集的问题,可以分为传统图像变换的数据增强方式和基于生成对抗网络的数据增强方式。传统意义上的数据增强,是通过对图像进行一些简单的变换操作来增加训练数据量,例如旋转、翻转、缩放、平移、尺度变换、噪声扰动、颜色变换等。通过这些几何变换可以增加训练集的样本量,减少网络的过拟合问题。但这与水声通信信号数据增强的初衷不符,因此无法使用传统意义的数据增强,考虑基于生成对抗网络的数据增强方式。

自从2014年,Goodfellow<sup>[44]</sup>等人提出了生成对抗网络(Generative Adversarial Networks, GAN)之后,数据增强技术具有了新的方法。GAN不需要任何先验信息,通过对真实样本分布的学习,使用随机噪声生成具有相似分布的数据样本,以此达到数据增强的目的;2014年, Mirza<sup>[45]</sup>等人在 GAN 的基础上引入了条件信息,提出了条件生成对抗网络(Conditional GAN, CGAN),通过给生成器中加入条件信息,控制了 GAN 的数据生成类别;2015年, Radford<sup>[46]</sup>等人使用卷积层代替了 GAN 的全连接层提出了深度卷积生成对抗网络(Deep Convolutional GAN, DCGAN),通过池化、采用批量标准化层(Batch Normalization, BN)以及 LeakyReLU 激活函数等训练技巧解决了 GAN 的训练过程难收敛、样本缺乏多样性的问题;2017年, Odena<sup>[47]</sup>等人提出了辅助分类生成对抗网络(Auxiliary Classifier GAN, ACGAN),ACGAN 模型在 CGAN 的基础上,使判别器不仅仅判断输入数据的真伪,还判断输入数据的类别。在此基础上, GAN 不断发展,先后出现了 VAE-GAN<sup>[48]</sup>、WGAN<sup>[49]</sup>、StackGAN<sup>[50]</sup>、CycleGAN<sup>[51]</sup>等模型。

在实际应用中,使用 GAN 进行数据增强的方式可以完全避免重复繁琐的人工标注图像过程。2016年, Isola<sup>[52]</sup>等人提出了 pixel2pixel 模型,通过学习数据对之间的映射,训练一个 CGAN 模型,实现图像转换。2018年, Wang<sup>[53]</sup>等人提出了 PAN(Perceptual Adversarial Networks)算法,通过将 pixel2pixel 中图像逐像素替换为特征图,使得生成图像更接近真实图像。

在无线电领域, Tang<sup>[54]</sup>等人于2018年提出了基于数据增强的数字信号识别方法,通

过生成对抗网络对数字信号星座图进行数据增强,研究了不同生成数据量下信号识别的性能。在水声领域,生成对抗网络的应用才刚刚起步。2019年,姚晓辉<sup>[55]</sup>等人提出一种基于生成对抗网络的特征提取方法,通过生成对抗网络提取信号的深层特征,以提升分类的准确率。

由于水声信号受到海洋环境的不均匀性和复杂多变性影响,水声信号获取困难,水声数据样本集的规模因此受限。因此,使用生成对抗网络对水声通信信号进行数据增强对机器学习技术在水声通信信号识别中的应用具有重要作用。针对水声通信信号数据量不足的问题,本文拟研究基于生成对抗网络的水声通信信号数据增强方法,并研究其在水声通信信号识别的影响。

### 1.2.3 迁移学习技术研究现状分析

迁移学习(Transfer Learning, TL)包含“域”和“任务”两个重要概念<sup>[56]</sup>。域(domain,  $\mathcal{D}$ )是由两部分组成:特征空间  $\mathcal{X}$  和边缘概率分布  $P(X)$ , 其中  $X = \{x_1, x_2, \dots, x_n\} \in \mathcal{X}$ 。当给定一个域  $\mathcal{D} = \{\mathcal{X}, P(X)\}$  时,任务(task,  $\mathcal{T}$ )可以定义为  $\mathcal{T} = (\mathcal{Y}, f(\cdot))$ , 是由类别空间  $\mathcal{Y}$  和预测函数  $f(\cdot)$  组成,能够通过学习满足  $x_i \in \mathcal{X}$ ,  $y_i \in \mathcal{Y}$  的训练数据  $\{x_i, y_i\}$  得到。预测函数  $f(\cdot)$  预测样本  $x$  对应的标签为  $f(x)$ , 从概率的角度来看,其等价于条件概率分布  $P(y|x)$ 。

给定一个域  $\mathcal{D}_s = \{(x_{s_1}, y_{s_1}), \dots, (x_{s_n}, y_{s_n})\}$  和学习任务  $\mathcal{T}_s$  以及另一个域  $\mathcal{D}_t = \{(x_{t_1}, y_{t_1}), \dots, (x_{t_m}, y_{t_m})\}$  和学习任务  $\mathcal{T}_t$  (满足  $0 < m \ll n$ ), 迁移学习就是在  $\mathcal{D}_s \neq \mathcal{D}_t$  或者  $\mathcal{T}_s \neq \mathcal{T}_t$  的条件下,通过获取  $\mathcal{D}_s$  和  $\mathcal{T}_s$  的知识来提升  $\mathcal{D}_t$  中的预测函数  $f_{\mathcal{T}}(\cdot)$  的学习,那么可以将  $\mathcal{D}_s$  称为源域(source domain),  $\mathcal{D}_t$  称为目标域(target domain)。

根据特征空间、类别空间、边缘概率分布、条件概率分布的异同,可以将迁移学习分为同构迁移学习和异构迁移学习<sup>[57]</sup>。其中,将满足  $\mathcal{X}_s \cap \mathcal{X}_t \neq \emptyset$  且  $\mathcal{Y}_s = \mathcal{Y}_t$ ,  $P_s(X) \neq P_t(X)$  或  $P(Y_s|X_s) \neq P(Y_t|X_t)$  的迁移学习类型称为同构迁移学习,将满足  $\mathcal{X}_s \cap \mathcal{X}_t = \emptyset$  或  $\mathcal{Y}_s \neq \mathcal{Y}_t$  的迁移学习类型称为异构迁移学习。

根据不同迁移学习算法所使用的方法,可以将迁移学习分为四类<sup>[57]</sup>: 基于样本的迁移学习算法、基于特征的迁移学习算法、基于对抗的迁移学习算法和基于模型的迁移学习算法。

基于样本的迁移学习主要是根据源域和目标域中样本的相关情况,制定权重调解方案,以一定的权重将源域中的部分样本补充到目标域中。当目标域数据集规模小,则分类模型的方差偏高,泛化误差大,通过加入部分源域数据,可以减小模型的方差。但是

当源域和目标域数据的分布差距很大时,新模型的偏差会很高。因此使用基于样本的迁移学习算法需要源域和目标域的数据具有相似分布<sup>[58]</sup>。

基于特征的迁移学习算法是通过将源域和目标域中的所有数据样本根据一定的映射关系,映射到一个新的特征空间中,从而减少了源域和目标域之间的差异性,然后使用映射在特征空间内的数据训练目标分类模型。基于特征的迁移学习算法可以通过最小化源域和目标域的最大均值差异得到映射后的特征空间<sup>[59]</sup>,在此空间中,源域和目标域的数据样本具有相同或者相似的空间分布。

基于对抗的迁移学习算法主要是受生成对抗网络的启发,通过对抗原理的相关算法,找到在源域和目标域中均适用的特征,从而进行迁移。其中,典型算法为对抗判别领域适应(Adversarial Discriminative Domain Adaptation, ADDA)算法<sup>[60]</sup>,它通过将生成对抗网络的损失函数和判别基础模型相结合,取消了权重共享,最终实现了基于对抗的迁移学习。

基于模型的迁移学习算法主要是通过使用源域数据训练分类模型,然后将该模型的全部或者部分网络权重或者结构迁移到目标域模型中。使用源域数据预训练的模型可以避免再次训练数据,这就使得基于模型的迁移学习可以更加高效地实现目标域数据的分类识别。这也是目前在实际场景中应用最广泛的迁移学习算法,例如在历年 ImageNet 挑战赛中的冠军模型 AlexNet<sup>[61]</sup>、ZFNet<sup>[62]</sup>、VGG<sup>[63]</sup>、GoogleNet<sup>[64]</sup>、ResNet<sup>[65]</sup>、SENet<sup>[66]</sup>等卷积神经网络模型均在迁移学习领域得到了广泛应用。

在无线电通信信号识别领域,Gao<sup>[67]</sup>等人于2019年提出了一种基于迁移学习的雷达信号调制模式识别技术,使用基于迁移学习的卷积神经网络提取图像信息,最终实现了12种不同调制模式信号的识别;2020年,Bu<sup>[68]</sup>等人提出了一种对抗性迁移学习架构,结合了对抗性训练和知识迁移,大大提高了目标模型的识别性能;同年,Xiao<sup>[69]</sup>等人提出了自动雷达波形识别系统,针对不同雷达信号的CWD图像,使用基于迁移学习的卷积神经网络模型,在低信噪比下实现了对雷达信号的有效识别。在水声通信信号识别领域,迁移学习的应用才刚刚起步。2019年,邵梦琦<sup>[41]</sup>将基于迁移学习的GoogleNet模型应用于水声通信信号识别,实现对BPSK、QPSK、8PSK、OFDM和DSSS信号的识别。

针对基于卷积神经网络的水声通信信号识别方法在数据量不足条件下识别效果较差的问题,本文拟研究基于迁移学习的水声通信信号识别技术,通过基于卷积神经网络模型的迁移学习方法提高水声通信信号识别效果。



### 1.3 论文的主要研究内容和结构安排

本文主要针对实际水声通信侦察中水声通信信号数据量不足导致以卷积神经网络为代表的深度学习算法无法直接应用于水声通信信号识别的问题,通过基于生成对抗网络的数据增强方法进行水声通信信号数据集的扩充,并通过迁移学习的方法进一步提高卷积神经网络对水声通信信号的识别效果。

本文的主要研究内容分为基于卷积神经网络的水声通信信号识别技术、基于数据增强的水声通信信号识别技术和基于迁移学习的水声通信信号识别技术,具体研究方案如图 1.2 所示。

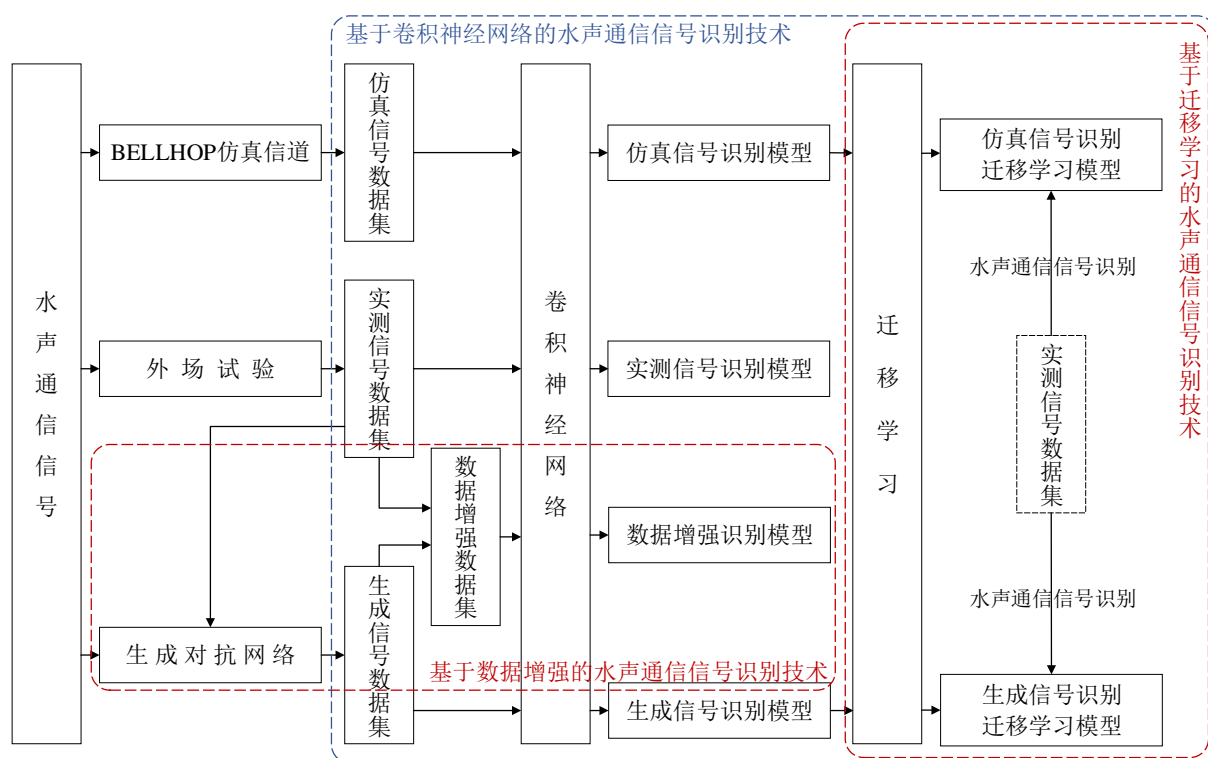


图 1.2 论文研究方案

本文对应的章节安排如下：

**第 1 章：绪论。**阐述了本文的研究背景及意义，介绍了机器学习在水声领域尤其是水声通信信号识别领域的研究现状，介绍了数据增强技术和迁移学习技术的研究现状，介绍了本文的研究内容和结构安排。

**第 2 章：卷积神经网络在水声通信信号识别中的应用分析。**首先，设计了水声通信信号类间识别和类内识别相结合的识别方案，包括水声通信信号的特征提取和卷积神经网络模型设计。然后，对水声通信信号识别方案进行了仿真研究，验证了基于时序信号的 1DCNN 模型、基于时频特征的 2DCNN 模型以及基于循环谱特征的 2DCNN 模型的

识别效果。最后，使用松花湖实测水声通信信号在不同数据量条件下对识别方案进行了试验研究和应用分析。

第3章：基于数据增强的水声通信信号识别技术。首先，设计了水声通信信号数据增强研究方案。然后，根据数据增强方案提出了一种水声通信信号生成对抗网络(UWACS-GAN)模型并针对松花湖实测水声通信信号进行信号生成。最后，使用生成信号和等量仿真信号对实测水声通信信号数据集进行数据增强，并采用水声通信信号识别的方法对数据增强效果进行分析，验证基于 UWACS-GAN 模型的数据增强方法的可行性。

第4章：基于迁移学习的水声通信信号识别技术。首先，介绍了基于卷积神经网络的迁移学习方法和策略，并设计了基于迁移学习的水声通信信号识别方案。然后，分别以仿真信号和 UWACS-GAN 生成信号为源域，以少量松花湖实测水声通信信号为目标域进行基于卷积神经网络模型的迁移学习的水声通信信号识别试验。最后，对本文所有水声通信信号识别算法进行对比，并总结最终的水声通信信号识别方案。



## 第2章 卷积神经网络在水声通信信号识别中的应用分析

近年来,卷积神经网络逐渐应用到水声通信信号识别领域,推动了自动调制模式识别技术的发展。卷积神经网络通过学习输入样本之间的差异,提取深层次的特征实现对样本的分类识别,具有较好的鲁棒性和泛化能力。

不同调制模式的水声通信信号具有不同的特征,例如 MFSK 信号利用载波的不同频率来表征信息, MPSK 信号利用载波的不同相位状态来表征信息, OFDM 信号通过叠加多种不同调制方式的子载波调制, DSSS 信号通过对不同类型的 PN 码序列进行载波调制。这四类水声通信信号之间存在明显差异,但 MPSK 信号(BPSK、QPSK 和 8PSK)以及 MFSK 信号(2FSK 和 4FSK)类内之间存在一定的相似性,采用单一模型实现水声通信信号的识别存在一定问题。

本章针对 MPSK、OFDM、DSSS 和 MFSK 四类常用水声通信信号采用小波变换提取时频特征,采用循环谱分析提取 MPSK 和 MFSK 信号的循环谱特征,根据以上特征采用卷积神经网络进行水声通信信号识别仿真实验和试验研究,并进行应用分析。

### 2.1 水声通信信号识别方案

本文主要针对 MPSK、OFDM、DSSS 和 MFSK 四类常用水声通信信号开展调制模式识别研究,包括实现 MPSK、OFDM、DSSS 和 MFSK 信号的类间识别以及 MPSK 信号和 MFSK 信号的类内识别。通过在调制过程中设置不同的参数产生多种水声通信信号,例如 MPSK 信号通过设置多种相位状态产生 BPSK、QPSK、8PSK 信号, OFDM 信号的子载波调制方式分别设置为 BPSK、QPSK、8PSK, DSSS 信号 PN 码序列分别采用 5/7/9 阶 m 序列, MFSK 信号通过设置多种载波频率产生 2FSK、4FSK 信号。由于调制模式的不同,四大类水声通信信号之间具有较大的差异,而 BPSK、QPSK、8PSK 三种 MPSK 信号之间则存在一定的相似性, 2FSK、4FSK 两种 MFSK 信号也是如此,因此无法只采用一个水声通信信号识别模型实现四类水声通信信号的类间识别以及 MPSK 和 MFSK 信号的类内识别。针对以上问题,本文提出以下水声通信信号类间识别与类内识别相结合的水声通信信号识别方案。

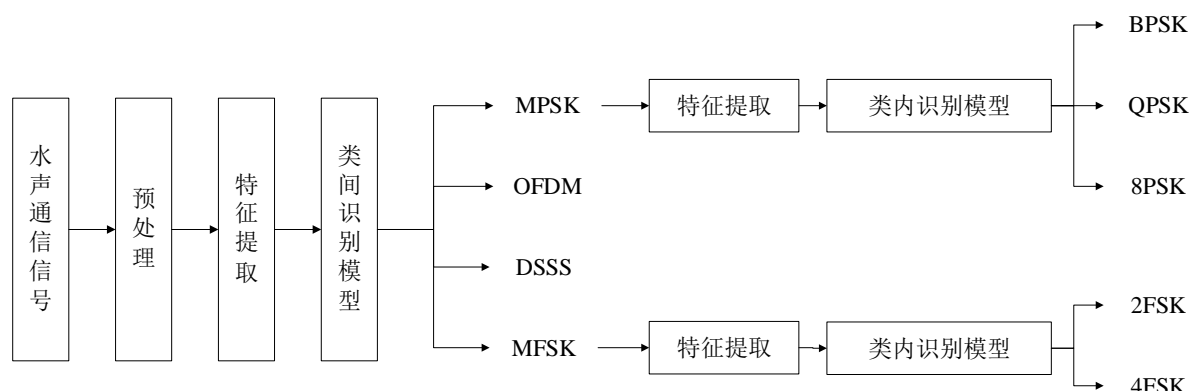


图 2.1 水声通信信号识别方案

本方案采用卷积神经网络作为水声通信信号识别模型，首先对水声通信信号进行分段和归一化等预处理操作，然后针对不同的识别目的进行特征提取，最后进行水声通信信号识别。针对水声通信信号类间识别，本章开展了两种算法研究：(1)针对预处理后的水声通信信号，开展基于时序信号的水声通信信号类间识别算法研究；(2)通过小波变换绘制四类水声通信信号的时频图作为时频特征，开展基于时频特征的水声通信信号类间识别算法研究。针对水声通信信号类内识别(主要研究 MPSK 和 MFSK 信号)，本章开展了三种算法研究：(1)研究基于时序信号的水声通信信号类内识别算法，分别应用于 MPSK 信号和 MFSK 信号的类内识别；(2)采用小波变换方法提取 MPSK 信号和 MFSK 信号的时频特征，研究基于时频特征的水声通信信号类内识别算法；(3)采用循环谱分析方法提取 MPSK 信号和 MFSK 信号的循环谱特征，研究基于循环谱特征的水声通信信号类内识别算法。

本节提出了水声通信信号类间识别和类内识别相结合的水声通信信号识别方案，本章将在此基础上开展基于卷积神经网络的水声通信信号识别技术研究，并对其在不同数据量条件下的应用进行分析。

## 2.1.1 水声通信信号特征提取

本节针对水声通信信号识别方案要求，使用小波变换和循环谱分析方法对水声通信信号进行特征提取。

### 2.1.1.1 基于小波变换的时频特征提取

对于信号  $s(t)$ ，将连续小波变换<sup>[70]</sup>的公式定义为

$$W_s(a, b) = \int s(t) \psi_{(a, b)}^*(t) dt = \frac{1}{\sqrt{a}} \int s(t) \psi^* \left( \frac{t-b}{a} \right) dt \quad (2-1)$$

式中， $a$  为尺度因子， $b$  为平移因子， $*$  表示共轭， $\psi(t) \in L^2(R)$  为小波基函数且满足完

全重构条件

$$C_{\psi} = \int_R \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega < \infty \quad (2-2)$$

其中,  $\hat{\psi}(\omega)$  为  $\hat{\psi}(t)$  的傅里叶变换。将小波基函数  $\psi(t)$  经过伸缩和平移变换后可得小波序列

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) \quad a, b \in R; a \neq 0 \quad (2-3)$$

在实际应用中, 需要对尺度因子  $a$  和平移因子  $b$  进行离散化处理<sup>[70]</sup>。令尺度因子  $a$  和平移因子  $b$  的离散化公式为  $a = a_0^m$ ,  $b = na_0^m b_0$ 。其中,  $m, n \in Z$ ,  $a_0$  为大于 1 的常数,  $b_0$  为大于 0 的常数, 对应的离散小波函数为

$$\psi_{m,n}(t) = \frac{1}{\sqrt{a_0^m}} \psi\left(\frac{t - na_0^m b_0}{a_0^m}\right) = \frac{1}{\sqrt{a_0^m}} \psi(a_0^{-m}t - nb_0) \quad (2-4)$$

相应的离散小波变换表示为

$$W_s(m, n) = \int_{-\infty}^{+\infty} s(t) \psi_{(m,n)}^*(t) dt \quad (2-5)$$

本节选择广义 Morse 小波作为小波基函数, 对水声通信信号进行小波分解得到小波系数, 绘制时频图, 并以热力图的形式作为本文水声通信信号的时频特征。

广义 Morse 小波<sup>[71]</sup>的频域表达式为

$$\Psi_{\beta,\gamma}(\omega) = \int_{-\infty}^{+\infty} \psi_{\beta,\gamma}(t) e^{-i\omega t} dt = U(\omega) a_{\beta,\gamma} \omega^{\beta} e^{-\omega^{\gamma}} \quad (2-6)$$

式中,  $U(\omega)$  为单位阶跃函数,  $a_{\beta,\gamma}$  为标准常数满足  $a_{\beta,\gamma} = 2(e\gamma / \beta)^{\beta/\gamma}$ , 广义 Morse 小波通过调整  $\beta$  和  $\gamma$  两个参数来调整调整波形和特性。通过选取合适的参数, 广义 Morse 小波可以和任一信号相似, 具有完全解析性, 因此基于广义 Morse 小波变换后可以最大程度保留信号的信息。

### 2.1.1.2 基于循环谱分析的循环谱特征提取

水声通信信号由于在预处理阶段进行了周期性处理(采样、编码、复用以及载波调制等)而具有循环平稳特性, 其特点是均值和自相关函数呈现周期性变化。

设  $x(t)$  是一个循环平稳信号, 则其均值  $m_x(t)$  和自相关函数  $R_x(t, \tau)$  是以  $T_0$  为周期的函数。

$$m_x(t) = m_x(t + nT_0) \quad (2-7)$$

$$R_x(t, \tau) = R_x(t + nT_0, \tau) \quad (2-8)$$

将公式(2-8)展开, 用傅里叶级数可表示为

$$R_x(t, \tau) = \sum_{m=-\infty}^{+\infty} R_x^{m/T_0}(\tau) e^{j2\pi m t / T_0} \quad (2-9)$$

设循环频率  $\alpha = m / T_0$ ,  $m$  为常数, 则公式(2-9)可表示为

$$R_x(t, \tau) = \sum_{\alpha=-\infty}^{+\infty} R_x^\alpha(\tau) e^{j2\pi \alpha t} \quad (2-10)$$

式中,  $R_x^\alpha(\tau)$  为傅里叶系数, 也称为循环自相关函数<sup>[72]</sup>, 表示为

$$\begin{aligned} R_x^\alpha(\tau) &= \frac{1}{T_0} \int_{-T_0/2}^{T_0/2} R_x(t, \tau) e^{-j2\pi \alpha t} dt \\ &= \lim_{T_0 \rightarrow +\infty} \frac{1}{T_0} \int_{-T_0/2}^{T_0/2} x(t + \frac{\tau}{2}) x^*(t - \frac{\tau}{2}) e^{-j2\pi \alpha t} dt \end{aligned} \quad (2-11)$$

由公式(2-11)可以看出, 一个循环平稳信号的循环频率  $\alpha$  可能有多, 当  $\alpha = 0$  时, 循环自相关函数退化为传统自相关函数。如果  $R_x^0(\tau)$  存在, 对任意  $\alpha \neq 0$ ,  $R_x^\alpha = 0$ , 则信号为平稳信号, 当至少对一个非零的  $\alpha$  有  $R_x^\alpha(\tau) \neq 0$  时, 信号才是循环平稳信号, 非零  $\alpha$  即为循环频率。

循环自相关函数  $R_x^\alpha(\tau)$  和循环谱密度函数  $S_x^\alpha(f)$  是一对傅里叶变换对, 则可以将循环谱密度函数  $S_x^\alpha(f)$  表示为

$$S_x^\alpha(f) = \int_{-\infty}^{+\infty} R_x^\alpha(\tau) e^{-j2\pi f \tau} d\tau \quad (2-12)$$

水声通信 MFSK 信号循环谱<sup>[73]</sup>为

$$\begin{aligned} S_{x_{MFSK}}^\alpha(f) &= \frac{1}{4T_d} \sum_{m=1}^M P_m [Q(f_m + f_m' + \frac{\alpha}{2}) Q^*(f_m + f_m' - \frac{\alpha}{2}) \\ &\quad + Q(f_m - f_m' + \frac{\alpha}{2}) Q^*(f_m - f_m' - \frac{\alpha}{2})] \end{aligned} \quad (2-13)$$

由公式(2-13)可以看出, MFSK 信号循环谱在  $\alpha = 0$  和  $f = f_m' = \pm(f_c + f_m)$  时有峰值, 峰值个数与  $f_m$  有关。

对于水声通信 MPSK 信号, 首先考虑 BPSK 信号循环谱<sup>[73]</sup>

$$S_{x_{BPSK}}^\alpha(f) = \begin{cases} \frac{1}{4T_d} [Q(f + f_c + \frac{\alpha}{2}) Q^*(f + f_c - \frac{\alpha}{2}) \\ \quad + Q(f - f_c + \frac{\alpha}{2}) Q^*(f - f_c - \frac{\alpha}{2})] e^{-j2\pi \alpha t_s}, & \alpha = \frac{m}{T_d} \\ \frac{1}{4T_d} [Q(f - f_c + \frac{\alpha}{2}) Q^*(f + f_c - \frac{\alpha}{2}) e^{-j2\pi(\alpha + 2f_c)t_s + 2\phi_0} \\ \quad + Q(f + f_c + \frac{\alpha}{2}) Q^*(f - f_c - \frac{\alpha}{2}) e^{-j2\pi(\alpha - 2f_c)t_s + 2\phi_0}], & \alpha = \frac{m}{T_d} \pm 2f_c \end{cases} \quad (2-14)$$

由公式(2-14)可以看出, BPSK 信号只有在  $\alpha = m / T_d$  和  $\alpha = m / T_d \pm 2f_c$  时具有循环平

稳特性。当  $M \geq 4$  时，MPSK 信号的循环谱<sup>[73]</sup>为

$$S_{x_{MPSK}}^{\alpha}(f)=\begin{cases} \frac{1}{2T_d}[Q(f+f_c+\frac{\alpha}{2})Q^*(f+f_c-\frac{\alpha}{2}) \\ +Q(f-f_c+\frac{\alpha}{2})Q^*(f-f_c-\frac{\alpha}{2})]e^{-j2\pi\alpha t_0}, & \alpha=\frac{m}{T_d} \\ 0, & \text{其他} \end{cases} \quad (2-15)$$

由公式(2-15)可知，此时 MPSK 信号在  $\alpha = m / T_d$  处具有循环平稳特性，且与 BPSK 信号循环谱存在明显差异。

将水声通信 MFSK 和 MPSK 信号的归一化循环谱图以热力图的形式作为本文水声通信信号识别的循环谱特征。

2.1.1.3 水声通信信号特征提取结果

水声通信 MPSK、OFDM、DSSS 和 MFSK 信号的类间识别需要四类信号的时域特征以及时频特征；水声通信 MPSK 信号以及 MFSK 信号的类内识别需要 BPSK、QPSK 和 8PSK 信号以及 2FSK 和 4FSK 信号的时域特征、时频特征和循环谱特征。因此，采用小波变换的方法提取水声通信信号的时频特征，绘制时频图，以热力图的形式作为水声通信信号识别的时频特征；采用循环谱分析的方法提取 MPSK 和 MFSK 信号的循环谱特征，绘制归一化循环谱图，以热力图的形式作为水声通信 MPSK 信号和 MFSK 信号类内识别的循环谱特征。表 2.1 为在理想无噪声条件下水声通信时序信号(时域波形)及其特征提取结果。

表 2.1 水声通信信号特征提取结果

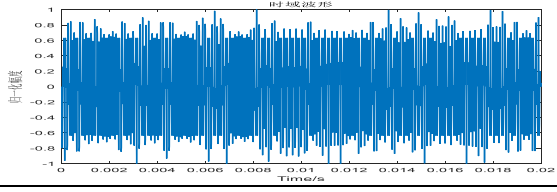
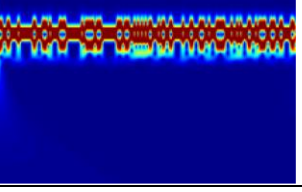
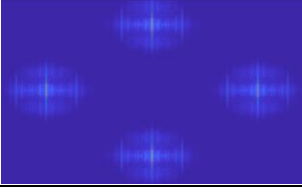
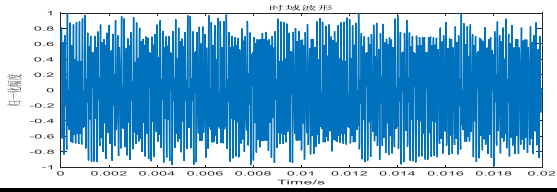
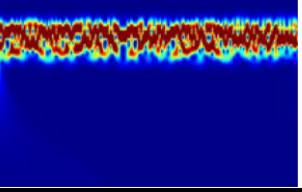
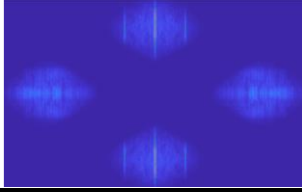
时序信号	时频特征	循环谱特征
BPSK		
		
QPSK		
		



表 2.1 水声通信信号特征提取结果

(续表)

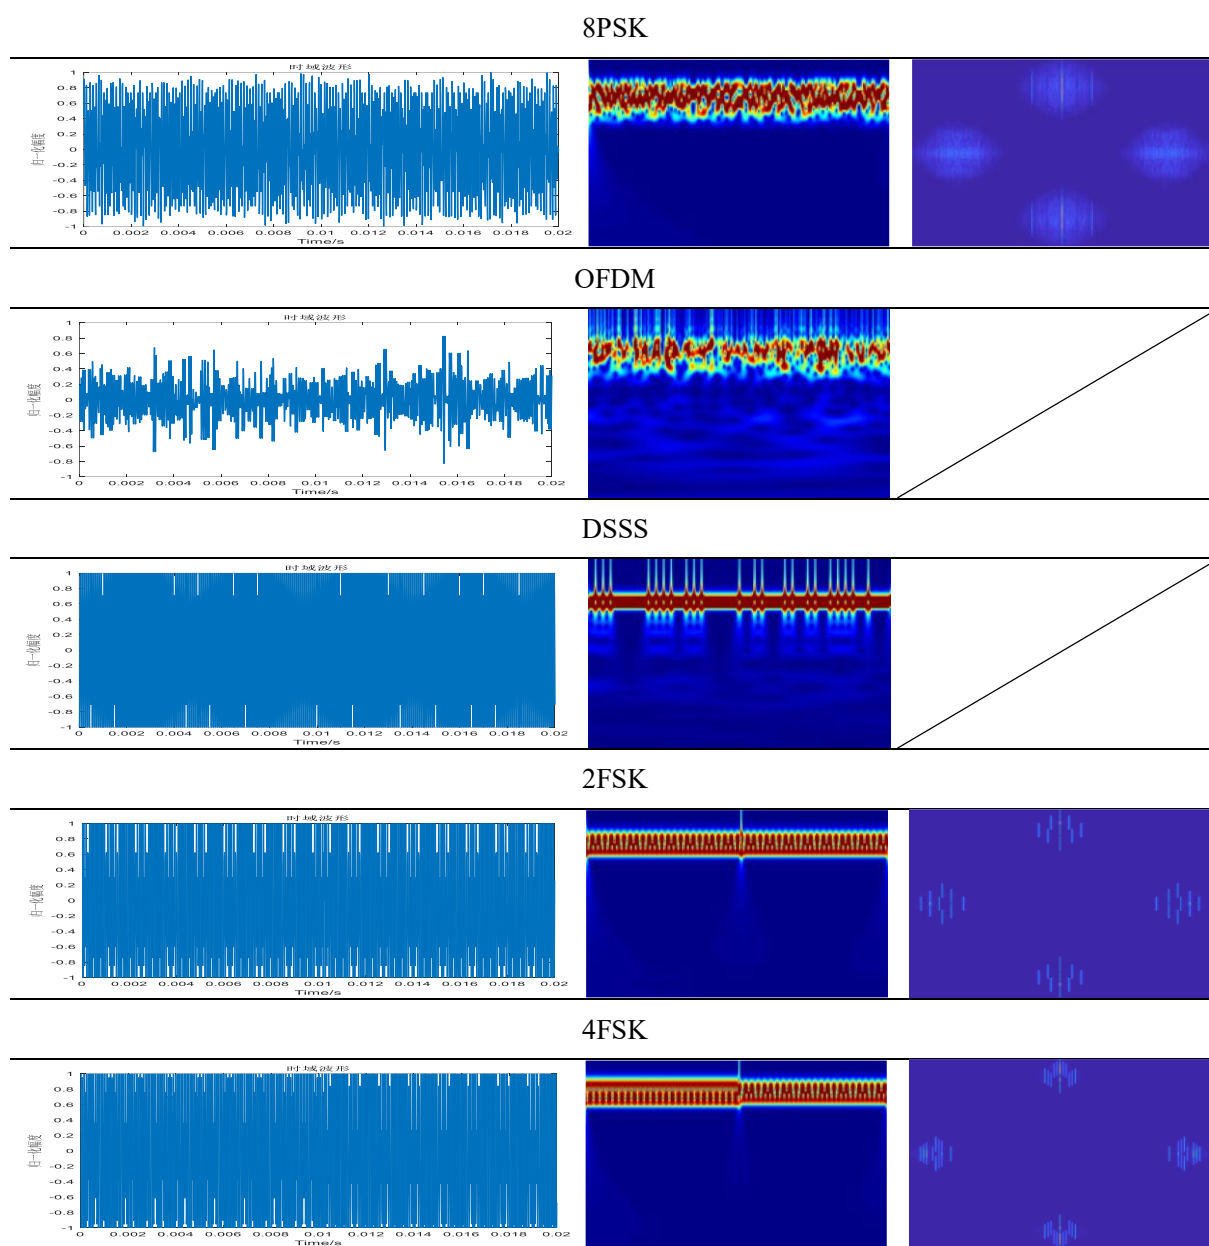


表 2.1 表明，MPSK、OFDM、DSSS 和 MFSK 信号的时域波形、时频特征差异显著，可以作为类间识别的依据；BPSK、QPSK 和 8PSK 信号的时域波形、时频特征之间存在一定的差异，尤其是时频特征差异较大，由于 QPSK 和 8PSK 信号的循环谱特征基本一致，本文决定先通过水声通信信号识别仿真实验研究其是否能作为 MPSK 信号类内识别的依据；2FSK 和 4FSK 信号的时域波形、时频特征、循环谱特征均存在显著的差异性，可以作为 MFSK 信号类内识别的依据。

## 2.1.2 水声通信信号识别卷积神经网络模型设计

卷积神经网络(Convolutional Neural Network, CNN)是受动物视觉皮层细胞感受野启

发,可以提取数据局部特征的一种神经网络模型,具有局部感受野、权值共享和池化三个主要特点。CNN 模型主要由输入层、隐藏层和输出层组成,其中隐藏层又可以分为卷积层和池化层。CNN 通过输入层将预处理的数据输入到隐藏层中,通过卷积层对输入数据提取局部特征,再通过池化层进行降采样,最后通过输出层完成分类识别任务。CNN 针对不同输入的维度,可以分为针对一维时序信号的一维卷积神经网络(1DCNN)<sup>[74]</sup>和针对二维图像的二维卷积神经网络(2DCNN)。

### 2.1.2.1 水声通信信号识别一维卷积神经网络模型设计

针对水声通信时序信号,本文设计的 1DCNN 模型由四个隐藏层、一个全连接层和一个输出层组成。四个隐藏层中,一维卷积层的卷积核个数分别为 16/32/64/128,大小均为 3,步长均为 1,采用 ReLU 激活函数;池化层均采用一维最大池化,池化大小为 2;为防止过拟合,均加入 Dropout 层,Dropout 率为 0.25。全连接层节点数为 512,采用 ReLU 激活函数;输出层节点数为信号类别数,采用 SoftMax 激活函数;优化算法采用 Adam 算法。本章设计的 1DCNN 模型具体结构如图 2.2 所示。




图 2.2 水声通信信号识别一维卷积神经网络模型结构设计

其中,第 $l$ 层隐藏层中的一维卷积层和一维最大池化层的运算过程可以表示为公式(2-16)和公式(2-17),输出层的 SoftMax 激活函数表达式为公式(2-18)。

$$\mathbf{x}_j^l = f(\mathbf{x}_j^{l-1} * \mathbf{k}_j^l + \mathbf{b}^l) \quad (2-16)$$

$$\mathbf{p}_i^l = \max([x_{2i-1}^{l-1}, x_{2i}^{l-1}]) \quad (2-17)$$

$$\varphi(\mathbf{p}_c) = \frac{e^{p_c}}{\sum_{c=1}^C e^{p_c}}, \quad c=1,2,\dots,C \quad (2-18)$$

式中,  $x_j^l$  表示第 $l$ 层的第 $j$ 个输出;  $\mathbf{k}^l = [k_1^l, k_2^l, \dots, k_m^l]$  表示第 $l$ 层一维卷积层的卷积核,是长度为  $m=16/32/64/128$  的一维向量;  $\mathbf{x}_j^{l-1} = [x_1^{l-1}, x_2^{l-1}, \dots, x_n^{l-1}]$  为第 $l$ 层一维卷积层的输入,是长度为 $n$ 的一维向量;  $\mathbf{b}^l$  表示第 $l$ 层的偏置;  $*$  表示卷积操作;  $f(\cdot)$  表示 ReLU 激活函数,其表达式为  $f_{\text{ReLU}}(x) = \max\{0, x\}$ ;  $[x_{2i-1}^{l-1}, x_{2i}^{l-1}]$  表示第 $l$ 层最大池化层的输入向量的输出,  $\max(\cdot)$  表示取这些输出中的最大值;  $C$  为输出层神经元数量对应调制模式类别数目,  $\mathbf{p}_c$  表示输出层中第 $c$ 个神经元的输出,  $\varphi(\mathbf{p}_c)$  为输入信号信号所属类别的概率分布。

### 2.1.2.2 水声通信信号识别二维卷积神经网络模型设计

针对水声通信信号提取的时频特征以及循环平稳特征，本文设计的 2DCNN 模型由四个隐藏层、一个全连接层和一个输出层组成。四个隐藏层中，二维卷积层的卷积核个数分别为 16/32/64/128，大小均为(3,3)，步长均为(1,1)，采用 ReLU 激活函数；池化层均采用二维最大池化，池化大小为(2,2)；为防止过拟合，均加入 Dropout 层，Dropout 率为 0.25；全连接层节点数为 512，采用 ReLU 激活函数；输出层节点数为信号类别数，采用 SoftMax 激活函数，优化算法采用 RMSProp 算法。本章设计的 2DCNN 模型具体结构如图 2.3 所示。




图 2.3 水声通信信号识别二维卷积神经网络模型结构

其中，第  $l$  层隐藏层中的二维卷积层和二维最大池化层的运算过程可以表示为公式(2-19)和公式(2-20)。

$$\mathbf{x}_j^l = f\left(\sum_{i \in M_j} \mathbf{x}_i^{l-1} * \mathbf{k}_{ij}^l + \mathbf{b}_j^l\right) \quad (2-19)$$

$$\mathbf{p}_{(i,j)}^l = \max(\mathbf{x}_{(m,n)}^{l-1}) \quad (2-20)$$

式中， $\mathbf{x}_j^l$  表示第  $l$  层卷积层的第  $j$  个输出的特征图， $\mathbf{x}_i^{l-1}$  表示第  $l$  层卷积层的第  $i$  个输入； $M_j$  是输入图像的集合； $f(\cdot)$  表示 ReLU 激活函数； $\mathbf{x}_{mn}^{l-1}$  表示第  $l$  层最大池化层的输入向量的第  $(m,n)$  个输出，其中  $m$  和  $n$  分别满足  $2i-1 \leq m \leq 2i$  和  $2j-1 \leq n \leq 2j$ ； $\mathbf{p}_{(i,j)}^l$  为第  $l$  层池化层第  $(i,j)$  个池化操作的输出。

### 2.1.3 水声通信信号识别效果评价指标

本文采用混淆矩阵、精确率、召回率和 F1 值作为水声通信信号识别效果评价指标。为方便介绍这几类评价指标，以二分类问题为例。

在二分类问题中，将所有样本分为正样本(P)和负样本(N)两类，模型预测结果分为正确(T)和错误(F)两类。因此，可以将结果分为四类：

TP：模型预测为正样本(P)，实际为正样本，预测正确(T)的样本；

FP：模型预测为正样本(P)，实际为负样本，预测错误(F)的样本；

TN：模型预测为负样本(N)，实际为负样本，预测正确(T)的样本；

FN：模型预测为负样本(N)，实际为正样本，预测错误(F)的样本。

以上四种样本构成了混淆矩阵，如图 2.4 所示，纵向为预测结果，横向为真实类别，

对角线表示模型正确识别的样本，本文为方便展示结果采用的是归一化混淆矩阵，即所有样本数目以其在该类样本中的比例展示。

		预测结果	
真实类别		TP	FN
		FP	TN

图 2.4 混淆矩阵

准确率(Accuracy)指的是模型预测正确的样本占有所有样本的比例。准确率直观清晰的显示了模型的分类性能。

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (2-21)$$

精确率(Precision, P)指的是模型预测为正样本的所有样本中，实际为正样本所占的比例。精确率显示了模型在预测某一类样本时错误分类的情况。

$$Precision = \frac{TP}{TP + FP} \quad (2-22)$$

召回率(Recall, R)指的是模型预测的正样本占有所有正样本的比例。召回率显示了模型在预测某一类样本时漏分类的现象。

$$Recall = \frac{TP}{TP + FN} \quad (2-23)$$

F1 值(F1-score, F1)是同时考虑精确率和召回率的综合评价指标，描述了模型的整体性能。

$$F1-score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (2-24)$$

在多分类问题中，将各个类别的精确率、召回率和 F1 值取平均，可以得到宏精确率(Marco-P)、宏召回率(Marco-R)和宏 F1 值(Marco-F1)。

$$Marco-P = \frac{1}{n} \sum_{i=1}^n P_i \quad (2-25)$$

$$Marco-R = \frac{1}{n} \sum_{i=1}^n R_i \quad (2-26)$$

$$Marco-F1 = \frac{1}{n} \sum_{i=1}^n F_{1_i} \quad (2-27)$$

## 2.2 基于卷积神经网络的水声通信信号识别仿真实验

本节针对四类常用水声通信信号识别进行仿真实验研究, 仿真信号是基于松花湖试验实测信号仿真得到, 分别采用基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型对 MPSK、OFDM、DSSS、MFSK 四类信号进行水声通信信号类间识别, 分别采用基于时序信号的 1DCNN 模型、基于时频特征的 2DCNN 模型和基于循环平稳特征的 2DCNN 模型分别对 MPSK(BPSK、QPSK、8PSK)信号和 MFSK(2FSK、4FSK)信号进行水声通信信号类内识别, 并对以上模型的抗噪性能进行仿真研究。

### 2.2.1 仿真条件

仿真实验采用 2019 年 12 月初采集的松花湖实测声速梯度, 如图 2.5 所示, 采用 BELLHOP 仿真信道。




图 2.5 松花湖实测声速梯度

仿真实验设置发射距离和发射深度与松花湖试验一致, 设置接收端固定, 为深度 5~30m、间隔 5m 的垂直水听器阵列。仿真实验采用多个发射深度、接收深度、水平距离产生多条 BELLHOP 仿真信道。其中发射声源深度 20m, 水平距离 1000m, 不同接收深度的仿真信道冲激响应如图 2.6(a)所示, 接收深度 20m 的仿真信道如图 2.6(b)所示。

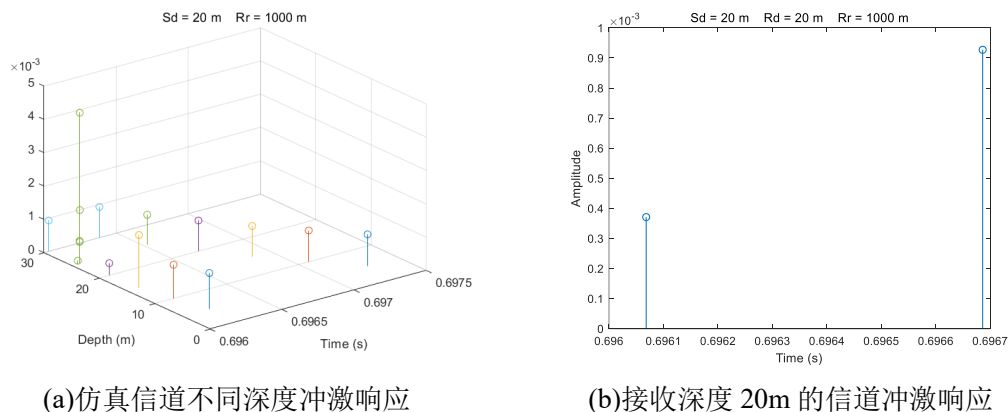


图 2.6 仿真信道冲激响应

### 2.2.2 仿真数据集说明

#### (1) 水声通信信号类间识别仿真数据集

水声通信信号类间识别仿真数据集设置如表 2.2 所示, 共采用 MPSK、OFDM、DSSS 和 MFSK 四类信号。

表 2.2 仿真数据集I设置

水声通信信号类型	MPSK	BPSK、QPSK、8PSK
	OFDM	子载波调制方式分别为 BPSK、QPSK、8PSK
	DSSS	BPSK 调制, 采用 5/7/9 阶 m 序列
	MFSK	2FSK、4FSK
样本长度	0.02s	
信噪比	-14dB~10dB, 步长 2dB, 窄带高斯白噪声	
训练集规模	24000 样本(每类 6000 样本)	
测试集规模	3600 样本(每类 1200 样本)	

#### (2) 水声通信信号类内识别仿真数据集

水声通信 MPSK 信号类内识别仿真实验数据集设置如表 2.3 所示, 共采用 BPSK、QPSK、8PSK 三种 MPSK 信号; 水声通信 MFSK 信号类内识别仿真实验数据集设置如表 2.4 所示, 共采用 2FSK 和 4FSK 两种 MFSK 信号。

表 2.3 仿真数据集II设置

水声通信信号类型	BPSK、QPSK、8PSK
样本长度	0.02s
信噪比	-14dB~10dB, 步长 2dB, 窄带高斯白噪声
训练集规模	6000 样本(每种 2000 样本)
测试集规模	1200 样本(每种 400 样本)

表 2.4 仿真数据集III设置

水声通信信号类型	2FSK、4FSK
样本长度	0.02s
信噪比	-14dB~10dB, 步长 2dB, 窄带高斯白噪声
训练集规模	6000 样本(每种 3000 样本)
测试集规模	1200 样本(每种 600 样本)

### 2.2.3 水声通信信号类间识别仿真实验结果

仿真实验分别采用基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型，对仿真数据集 I 中的 MPSK、OFDM、DSSS、MFSK 四类信号进行识别，并进行抗噪声性能仿真研究。两个模型的识别准确率随信噪比变化曲线如图 2.7 所示。

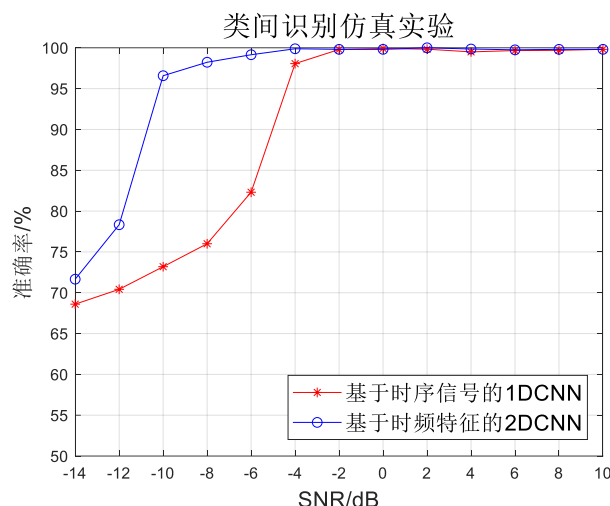


图 2.7 水声通信信号类间识别 CNN 模型抗噪性能曲线

结果表明，当信噪比大于等于 -2dB 时，两个模型的识别准确率均高于 99%；当信噪比小于等于 -4dB 时，2DCNN 模型识别准确率明显高于 1DCNN 模型；1DCNN 模型在信噪比下降到 -6dB 时，识别准确率迅速下降；2DCNN 模型则在信噪比下降到 -12dB 时，识别准确率迅速下降。综上所述，2DCNN 模型的抗噪性能要优于 1DCNN 模型。

基于时序信号的 1DCNN 模型识别准确率在信噪比为 -6dB 时下降为 82.31%，与信噪比为 -4dB 时的识别准确率(98.06%)相比下降 15.75 个百分点。进一步对这两个信噪比下的识别结果混淆矩阵进行分析，如图 2.8 所示。

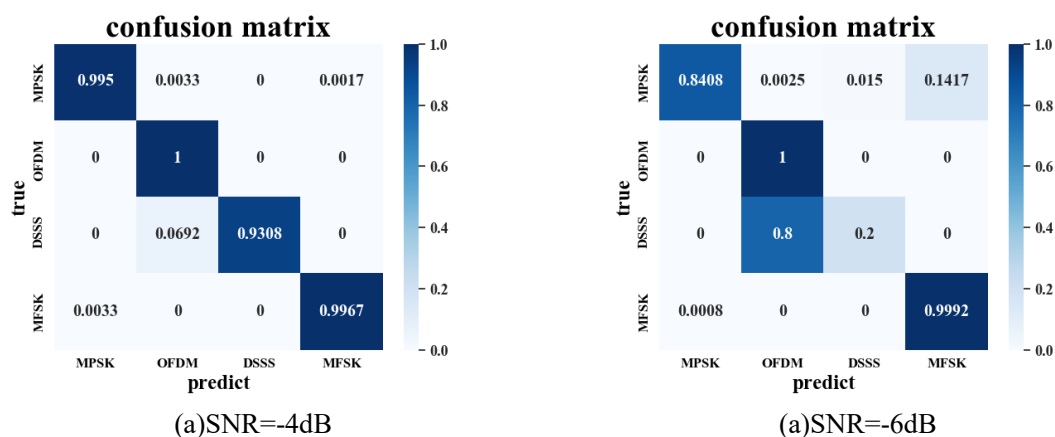


图 2.8 基于时序信号的 1DCNN 模型混淆矩阵

图 2.8 表明，当信噪比为 -4dB 时，基于时序信号的 1DCNN 模型基本能准确识别四

类信号,仅存在 6.92%的 DSSS 信号被误判为 OFDM 信号;当信噪比为-6dB 时,基于时序信号的 1DCNN 模型对 DSSS 信号识别失败,有 80.00%的 DSSS 信号被识别为 OFDM 信号,并且有 14.17%的 MPSK 信号被识别为 MFSK 信号。

基于时频特征的 2DCNN 模型识别准确率在信噪比为-12dB 时下降为 78.33%,与信噪比为-10dB 时的识别准确率(96.58%)相比下降 18.25 个百分点。进一步对这两个信噪比下的识别结果混淆矩阵进行分析,如图 2.9 所示。

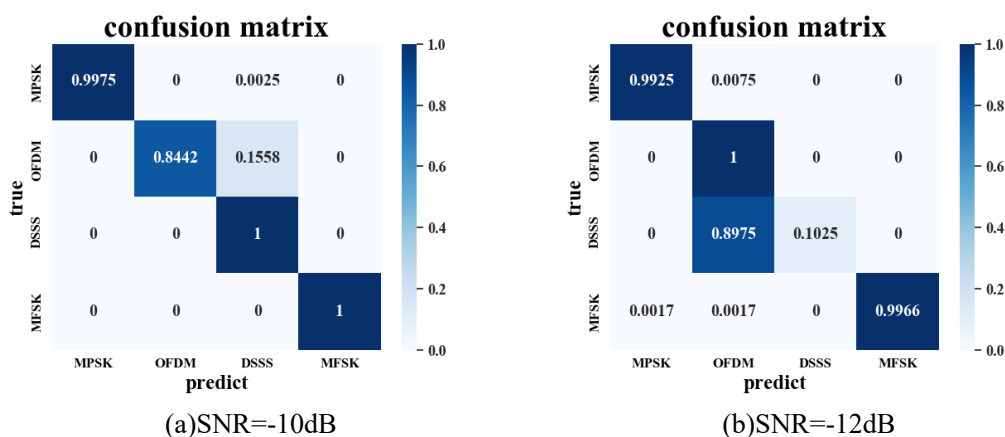


图 2.9 基于时频特征的 2DCNN 模型混淆矩阵

图 2.9 表明,当信噪比为-10dB 时,虽然基于时频特征的 2DCNN 模型识别准确率为 96.58%,但是有 15.58%的 OFDM 信号被识别为 DSSS 信号, MPSK 信号和 MFSK 信号能被准确识别;当信噪比为-12dB 时,基于时频特征的 2DCNN 模型对 DSSS 信号识别失败,接近 90%的 DSSS 信号被识别为 OFDM 信号, MPSK 信号和 MFSK 信号的识别准确率均高于 99%。

综上所述,本文提出的基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型在信噪比高于-4dB 时均能实现水声通信信号类间识别,且后者对噪声的敏感程度低于前者,即基于时频特征的 2DCNN 模型抗噪性更好。

## 2.2.4 水声通信信号类内识别仿真实验结果

### 2.2.4.1 MPSK 信号类内识别仿真实验结果

针对仿真数据集II,分别采用基于时序信号的 1DCNN 模型、基于时频图特征的 2DCNN 模型和基于循环谱特征的 2DCNN 模型,对 BPSK、QPSK、8PSK 信号进行识别,并进行抗噪性研究。三个模型的识别准确率随信噪比变化曲线如图 2.10 所示。



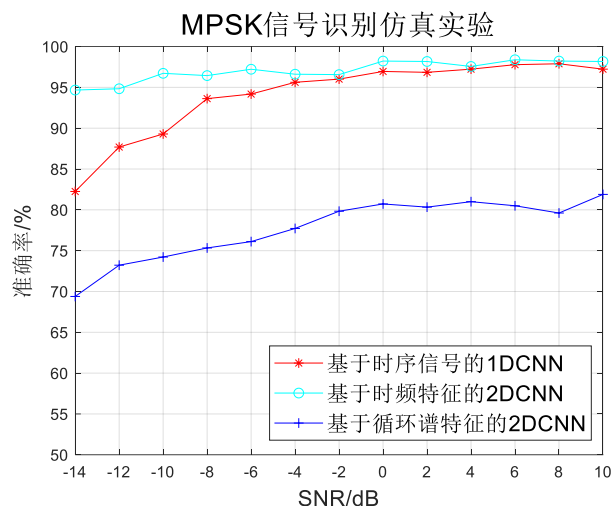


图 2.10 MPSK 信号类内识别 CNN 模型抗噪性能曲线

结果表明，基于时频特征的 2DCNN 模型对噪声敏感度最低，且识别准确率最高，保持在 95%以上，最高能达到 98%以上；在信噪比低于-4dB 时，基于时序信号的 1DCNN 模型和基于循环谱特征的 2DCNN 模型识别准确率随着信噪比的升高而提升，基于时序信号的 1DCNN 模型识别准确率相对较高；当信噪比高于-4dB 时，基于时序信号的 1DCNN 模型识别准确率稳定在 96%以上；基于循环谱特征的 2DCNN 模型识别准确率明显低于其他两种模型。图 2.11 给出了信噪比为-6dB 和 8dB 时基于循环谱特征的 2DCNN 模型测试集混淆矩阵。




图 2.11 基于循环谱特征的 2DCNN 模型测试集混淆矩阵

图 2.10 表明，当信噪比在-4dB 以下时，基于时序信号的 1DCNN 模型识别准确率迅速下降，基于时频特征的 2DCNN 模型识别准确率没有明显降低，低信噪比下，信号的时频特征比时域特征明显。图 2.11 表明，在高信噪比和低信噪比条件下，QPSK 和 8PSK 信号都容易混淆，这是因为 QPSK 和 8PSK 信号的循环谱特征不易区分。对于网络模型，特征也是重要的影响因素之一，通过以上对比，基于时频特征的卷积神经网络

是本文研究水声通信 MPSK 信号类内识别的重点。后续章节将给出基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型在水声通信 MPSK 信号类内识别中的应用分析。

#### 2.2.4.2 MFSK 信号类内识别仿真实验结果

针对仿真数据集Ⅲ, 分别采用基于时序信号的 1DCNN 模型、基于时频特征的 2DCNN 模型和基于循环谱特征的 2DCNN 模型, 对 2FSK 和 4FSK 信号进行识别, 并进行抗噪性研究。三个模型的识别准确率随信噪比变化曲线如图 2.12 所示。

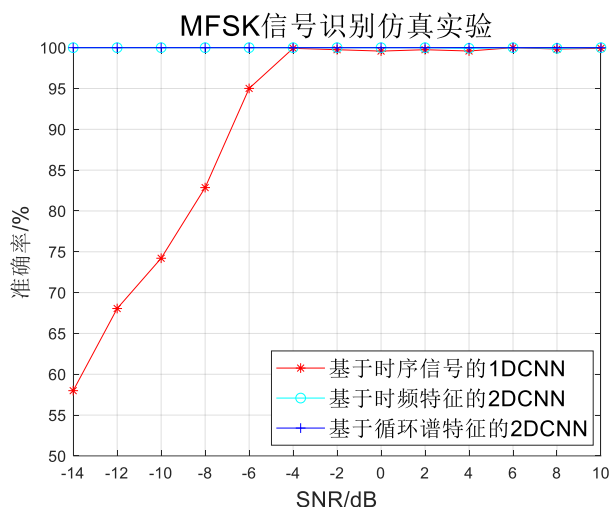


图 2.12 MFSK 信号类内识别 CNN 模型抗噪性能曲线

图 2.12 表明, 基于时频特征的 2DCNN 模型和基于循环谱特征的 2DCNN 模型可以准确识别 2FSK 和 4FSK 信号; 信噪比低于 -4dB 时, 基于时序信号的 1DCNN 模型对 2FSK 和 4FSK 信号的识别准确率迅速下降。根据表 2.1, 2FSK 和 4FSK 信号的时频特征和循环谱特征有明显差异, 因此基于以上特征的 2DCNN 模型具有较好的识别效果。

## 2.3 基于卷积神经网络的水声通信信号识别试验

本节基于仿真实验结果, 分别在水声通信信号数据量充足及数据量不足条件下, 开展基于卷积神经网络的水声通信信号识别试验研究, 并针对卷积神经网络在不同数据量下对实测水声通信信号识别的应用开展研究。

### 2.3.1 数据量充足条件下的水声通信信号识别试验

#### 2.3.1.1 松花湖试验数据集说明

水声通信信号识别试验使用数据为松花湖通信试验实测水声通信信号, 该试验于 2019 年 12 月初在吉林省吉林市松花湖开展, 具体试验布放如图 2.13 所示。试验过程中,

接收端为锚定的 32 元垂直水听器阵列，深度范围为 2m~33m，阵元间隔 1m，采样率为 96kHz；发射船在距离接收端水平距离 400m~1600m 的范围内定点发射，发射端发射深度范围为 6m~30m，间隔 2m，试验期间受风浪影响，发射船存在一定的漂移。

发射信号包含 MPSK 信号(BPSK、QPSK、8PSK)、OFDM 信号(子载波调制方式分别为 BPSK、QPSK、8PSK)、DSSS 信号(BPSK 调制， $m=5$ 、7、9 阶  $m$  序列)和 MFSK 信号(2FSK、4FSK)四类调制模式十一种信号。试验期间，共采集三千余组有效数据，随机取其中 3600 组数据进行水声通信信号识别试验研究，将预处理后的水声通信数据按照 5: 1 的比例分为训练集和测试集。水声通信信号类间识别数据集设置如表 2.5 所示，MPSK 信号类内识别数据集设置如表 2.6 所示，MFSK 信号类内识别数据集设置如表 2.7 所示。




图 2.13 松花湖试验仪器布置示意图

表 2.5 水声通信信号类间识别数据集I设置

水声通信信号类型	MPSK	BPSK、QPSK、8PSK
	OFDM	子载波调制方式分别为 BPSK、QPSK、8PSK
	DSSS	BPSK 调制， $m=5$ 、7、9 阶序列
	MFSK	2FSK、4FSK
样本长度	0.02s	
接收端信噪比	7~9dB	
训练集规模	24000 样本(每类 6000 样本)	
测试集规模	4800 样本(每种 1200 样本)	

表 2.6 MPSK 信号类内识别数据集II设置

水声通信信号类型	BPSK、QPSK、8PSK
样本长度	0.02s
信噪比	7~9dB
训练集规模	6000 样本(每种 2000 样本)
测试集规模	1200 样本(每种 400 样本)

表 2.7 MFSK 信号类内识别数据集III设置

水声通信信号类型	2FSK、4FSK
样本长度	0.02s
信噪比	7~9dB
训练集规模	6000 样本(每种 3000 样本)
测试集规模	1200 样本(每种 600 样本)

### 2.3.1.2 松花湖水声通信信号类间识别试验结果

针对数据集I, 分别采用基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型进行水声通信信号类间识别。两个模型的识别准确率分别为 84.43%和 92.19%, 测试集混淆矩阵如图 2.14 所示。根据混淆矩阵计算得到 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值, 结果如表 2.8 所示。

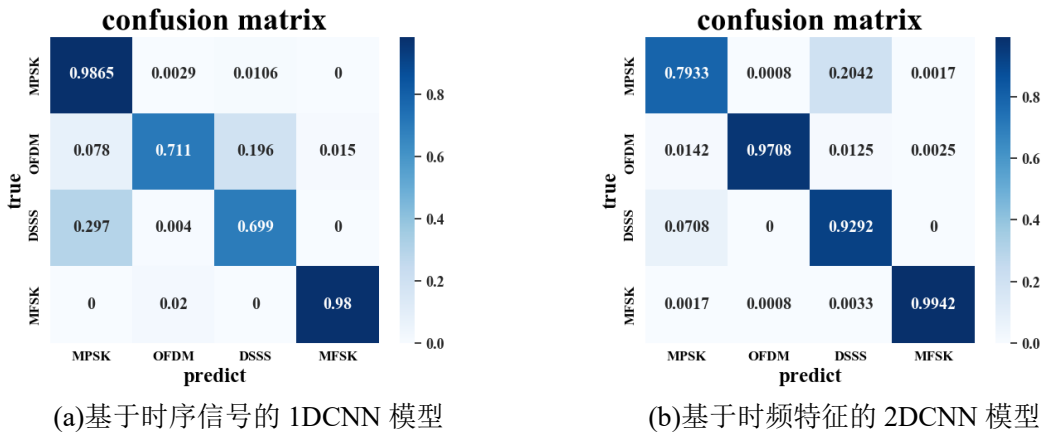


图 2.14 松花湖水声通信信号类间识别试验结果混淆矩阵

结果表明, 2DCNN 模型对四类信号的识别效果要优于 1DCNN 模型, 与仿真结果一致。对于 1DCNN 模型, 四类信号之间发生了不同程度的混淆, OFDM 和 DSSS 信号混淆严重。从三个评价指标来看, 对于 MFSK 信号识别效果明显由优于其他信号, 有较多的 OFDM 信号和 DSSS 信号被判别为 MPSK 信号, 因此 MPSK 信号精确率较低。但

图 2.8 和图 2.9 的仿真实验结果显示，主要是 OFDM 和 DSSS 信号之间发生混淆，湖试结果中 MPSK、OFDM 和 DSSS 之间有较大混淆，可能是因为湖试环境相对复杂，会引入干扰，导致识别效果下降。

表 2.8 松花湖水声通信信号类间识别试验性能评价指标

类间识别 模型	MPSK			OFDM		
	P	R	F1	P	R	F1
1DCNN	72.56%	98.65%	83.62%	96.35%	71.10%	81.82%
2DCNN	90.15%	79.33%	84.39%	99.84%	97.08%	98.44%

类间识别 模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN	77.19%	69.90%	73.36%	98.49%	98.00%	98.25%
2DCNN	80.86%	92.92%	86.47%	99.58%	99.42%	99.50%

### 2.3.1.3 松花湖水声通信信号类内识别试验结果

#### (1) MPSK 信号类内识别结果

针对数据集II，分别采用基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型进行 MPSK 信号类内识别。两个模型的识别准确率分别为 49.11%和 89.89%，测试集混淆矩阵如图 2.15 所示。根据混淆矩阵计算得到 BPSK、QPSK 和 8PSK 信号的精确率、召回率和 F1 值，结果如表 2.9 所示。




图 2.15 MPSK 信号类内识别试验结果混淆矩阵

结果表明，基于时序信号的 1DCNN 模型对 BPSK、QPSK 和 8PSK 信号的识别失败，三类信号混淆严重，基于时频特征的 2DCNN 模型能够较为准确地识别 BPSK、QPSK 和 8PSK 信号。这是因为 BPSK、QPSK 和 8PSK 信号的差异性主要是体现在相位不同，

时频分析中包含 MPSK 信号的相位信息。

表 2.9 MPSK 信号类内识别试验性能评价指标

MPSK 信号	基于时序信号的 1DCNN 模型			基于时频特征的 2DCNN 模型		
	P	R	F1	P	R	F1
BPSK	45.45%	52.50%	48.72%	93.82%	88.66%	91.17%
QPSK	46.03%	47.33%	46.67%	90.86%	87.83%	89.32%
8PSK	58.17%	47.50%	52.30%	85.60%	93.16%	89.22%

## (2) MFSK 信号类内识别结果

针对数据集Ⅲ，分别采用基于时序信号的 1DCNN 模型、基于时频特征的 2DCNN 模型和基于循环谱特征的 2DCNN 模型进行 MFSK 信号类内识别。三个模型的识别准确率分别为 72.42%、99.84%和 100.00%，测试集混淆矩阵图 2.12 所示。根据混淆矩阵计算得到 2FSK 和 4FSK 信号的精确率、召回率和 F1 值，结果如表 2.10 所示。

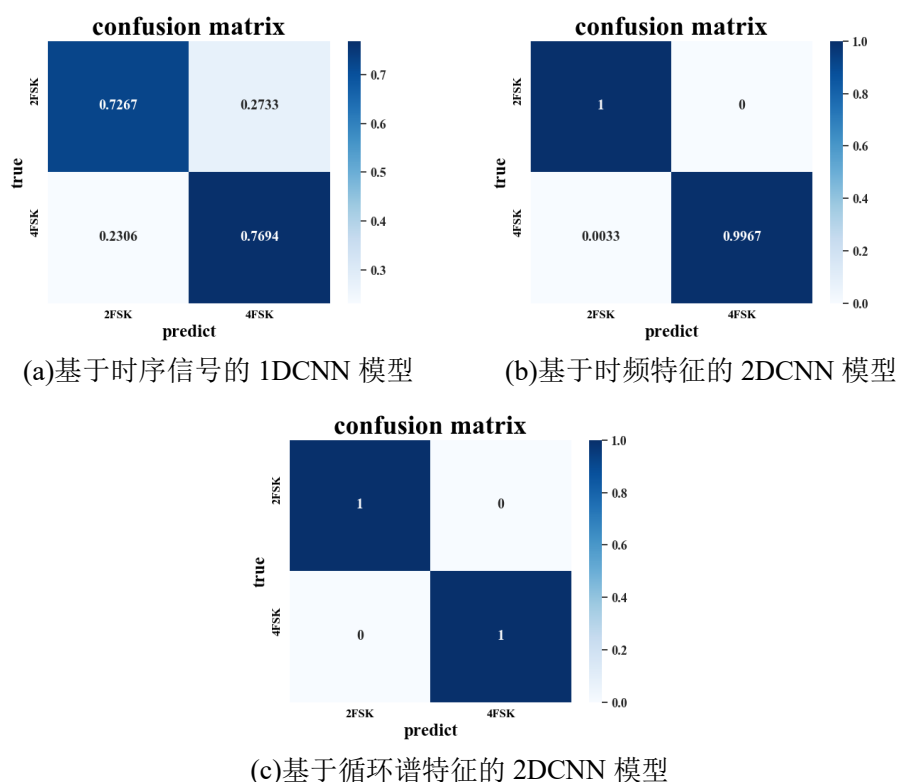


图 2.16 MFSK 信号类内识别结果混淆矩阵

结果表明，基于时频特征的 2DCNN 模型和基于循环谱特征的 2DCNN 模型可以准确识别 2FSK 和 4FSK 信号，而基于时序信号的 1DCNN 模型对 2FSK 和 4FSK 信号识别效果相对较差。这是因为时频分析和循环谱分析能够体现 2FSK 和 4FSK 信号载波频率上的差异。

表 2.10 MFSK 信号类内识别试验性能评价指标

MFSK 信号	基于时序信号的 1DCNN 模型			基于时频特征的 2DCNN 模型		
	P	R	F1	P	R	F1
2FSK	75.31%	72.67%	73.96%	99.67%	100.00%	99.83%
4FSK	73.59%	76.17%	74.86%	100.00%	99.67%	99.83%
MFSK 信号	基于循环谱特征的 2DCNN 模型					
	P	R	F1			
2FSK	100.00%	100.00%	100.00%			
4FSK	100.00%	100.00%	100.00%			

综上所述,在水声通信信号数据量充足条件下,本章设计的卷积神经网络模型可以实现 MPSK、OFDM、DSSS 和 MFSK 四类水声通信信号的类间识别、三种 MPSK 信号(BPSK、QPSK 和 8PSK)的类内识别以及两种 MFSK 信号(2FSK 和 4FSK)的类内识别。

### 2.3.2 数据量不足条件下的水声通信信号识别试验

实际水声通信侦察中并没有充足的数据量进行卷积神经网络模型的训练,本节给出了在数据量不足条件下的水声通信信号识别效果。

#### 2.3.2.1 数据量不足条件下水声通信信号类间识别试验

##### (1) 试验数据集说明

为模拟水声通信信号数据量不足的问题,分别从 3.4 节数据集 I 中的训练集和测试集随机抽取部分数据构成实验数据集 IV 的训练集和测试集。在此条件下, MPSK、OFDM、DSSS 和 MFSK 四类水声通信信号类间识别数据集设置如表 2.11 所示。

表 2.11 水声通信信号类间识别数据集 IV 设置

水声通信信号类型	MPSK	BPSK、QPSK、8PSK
	OFDM	子载波调制方式分别为 BPSK、QPSK、8PSK
	DSSS	BPSK 调制, $m=5、7、9$ 阶序列
	MFSK	2FSK、4FSK
样本长度	0.02s	
接收端信噪比	7~9dB	
训练集规模	4800 样本(每类 1200 样本), 下降 80%	
测试集规模	1200 样本(每类 300 样本)	

(2) 试验结果及分析

试验分别采用基于时序信号的 1DCNN-S 模型和基于时频特征的 2DCNN-S 模型对数据集IV进行水声通信信号类间识别。两个模型在水声通信信号数据量不足条件下的识别准确率分别为 63.24%和 56.25%，测试集混淆矩阵如图 2.17 所示。根据混淆矩阵计算得到 MPSK、OFDM、DSSS 和 MFSK 四类信号的精确率、召回率和 F1 值如表 2.12 所示。




图 2.17 数据量不足条件下水声通信信号类间识别结果

表 2.12 数据量不足条件下水声通信信号类间识别结果评价指标

类间识别 模型	MPSK			OFDM		
	P	R	F1	P	R	F1
1DCNN-S	56.54%	76.33%	64.96%	59.43%	49.33%	53.91%
2DCNN-S	46.49%	25.33%	32.79%	54.80%	44.67%	49.22%
类间识别 模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN-S	57.20%	42.33%	48.66%	78.70%	85.00%	81.73%
2DCNN-S	51.24%	69.00%	58.81%	66.50%	86.00%	75.00%

结果表明，在水声通信信号数据量不足条件下，两个模型的识别效果相比数据量充足时显著下降。综合三个评价指标，对于两个模型，四类信号混淆严重，分类失败。虽然 MFSK 信号的识别准确率较高，但是与其他三类信号混淆严重。

2.3.2.2 水声通信信号类内识别试验

(1) 试验数据集设置

针对数据量不足条件下的水声通信信号类内识别研究，以数据集IV中的 MPSK 和



MFSK 信号为基础, 建立 MPSK 信号类内识别数据集V和 MFSK 信号类内识别数据集VI, 数据集具体设置分别如表 2.13 和表 2.14 所示。

表 2.13 MPSK 信号类内识别数据集V设置

水声通信信号类型	BPSK、QPSK、8PSK
样本长度	0.02s
信噪比	7~9dB
训练集规模	1200 样本(每种 400 样本), 下降 80%
测试集规模	300 样本(每种 100 样本)

表 2.14 MFSK 信号类内识别数据集VI设置

水声通信信号类型	2FSK、4FSK
样本长度	0.02s
信噪比	7~9dB
训练集规模	1200 样本(每种 600 样本), 下降 80%
测试集规模	200 样本(每种 100 样本)

## (2) MPSK 类内识别试验结果及分析

试验分别采用基于时序信号的 1DCNN-S 模型和基于时频特征的 2DCNN-S 模型对数据集V进行 MPSK 信号类内识别。两个模型在水声通信信号数据量不足条件下对 MPSK 信号类内识别准确率分别为 36.67%和 46.33%, 测试集混淆矩阵如图 2.18 所示。根据混淆矩阵计算得到 BPSK、QPSK、8PSK 信号的精确率、召回率和 F1 值如表 2.15 所示。

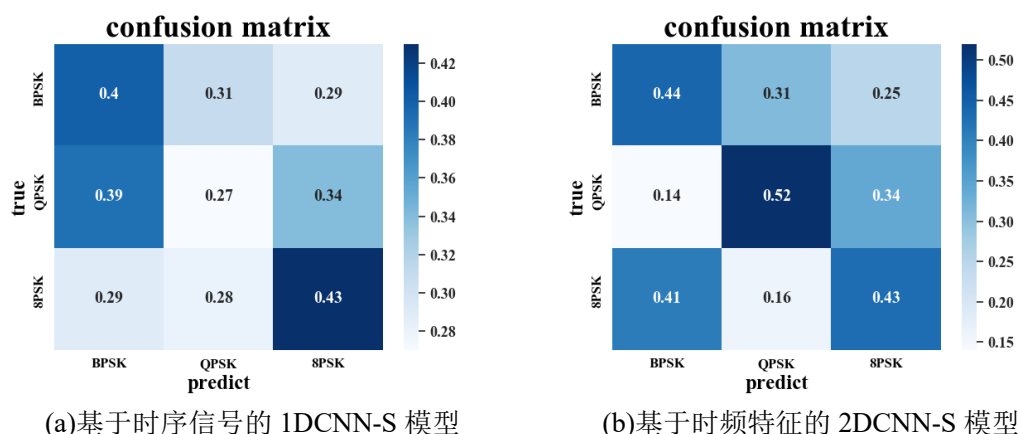


图 2.18 数据量不足条件下 MPSK 信号类内识别结果

表 2.15 数据量不足条件下 MPSK 信号类内识别结果评价指标

MPSK 信号	基于时序信号的 1DCNN-S 模型			基于时频特征的 2DCNN-S 模型		
	P	R	F1	P	R	F1
BPSK	37.04%	40.00%	38.46%	44.44%	44.00%	44.22%
QPSK	31.40%	27.00%	29.03%	52.53%	52.00%	52.26%
8PSK	40.57%	43.00%	41.75%	42.16%	43.00%	42.57%

结果表明,在水声通信信号数据量不足条件下,基于时序信号的 1DCNN-S 模型和基于时频特征的 2DCNN-S 模型的识别效果相比数据量充足时显著下降。综合三个评价指标,两个模型在水声通信信号数据量不足的情况下完全无法识别 BPSK、QPSK 和 8PSK 信号。

### (3) MFSK 信号类内识别结果及分析

试验分别采用基于时序信号的 1DCNN-S 模型、基于时频特征的 2DCNN-S 模型和基于循环谱特征的 2DCNN-S 模型对数据集 VI 进行 MFSK 信号类内识别。三个模型在数据量不足条件下对 MFSK 信号类内识别准确率分别为 54.50%、60.50%和 100.00%,测试集混淆矩阵如图 2.19 所示。根据混淆矩阵计算得到 2FSK、4FSK 信号的精确率、召回率和 F1 值如表 2.16 所示。

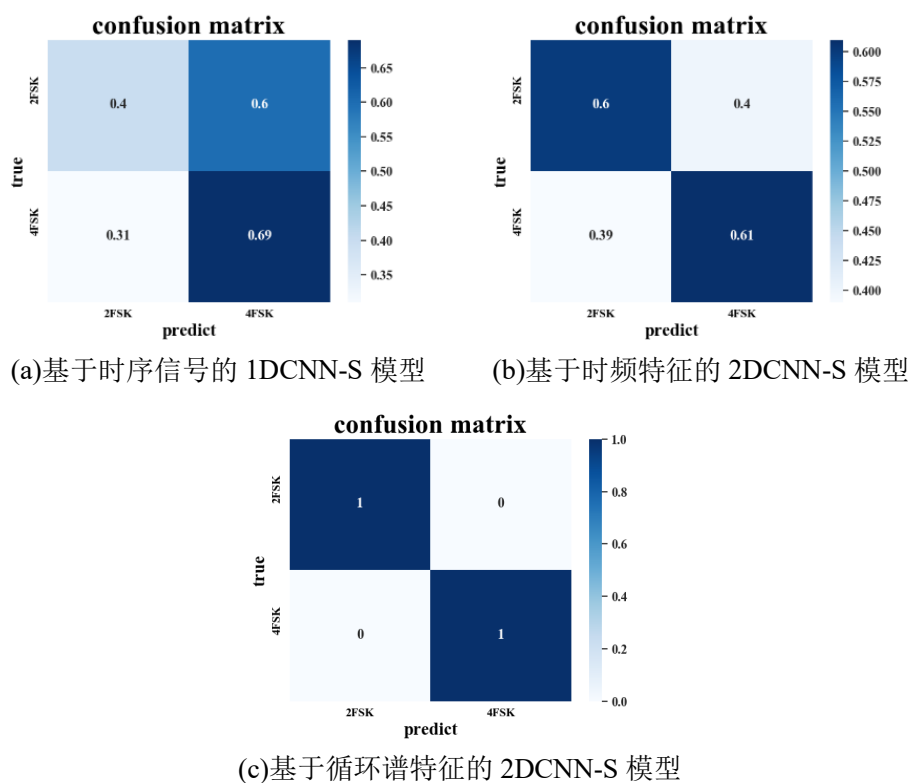


图 2.19 数据量不足条件下 MFSK 信号类内识别结果

表 2.16 数据量不足条件下 MFSK 信号类内识别结果评价指标

MFSK 信号	基于时序信号的 1DCNN-S 模型			基于时频特征的 2DCNN-S 模型		
	P	R	F1	P	R	F1
2FSK	56.34%	40.00%	46.78%	60.61%	60.00%	60.30%
4FSK	53.49%	69.00%	60.26%	60.40%	61.00%	60.40%
MFSK 信号	基于循环谱特征的 2DCNN-S 模型					
	P	R	F1			
2FSK	100.00%	100.00%	100.00%			
4FSK	100.00%	100.00%	100.00%			

结果表明, 基于循环谱特征的 2DCNN-S 模型在水声通信信号数据量不足条件下仍能准确识别 2FSK 和 4FSK 信号, 但是其他两个模型识别失败。

综上所述, 在水声通信信号数据量充足条件下, 本章设计的基于卷积神经网络的水声通信信号识别算法可以实现水声通信 MPSK、OFDM、DSSS 和 MFSK 信号的类间识别, 实现 MPSK 信号的类内识别以及 MFSK 信号的类内识别; 但是在水声通信信号数据量不足条件下, 基于时序信号的 1DCNN-S 模型和基于时频特征的 2DCNN-S 模型无法实现水声通信信号识别, 只有基于循环谱特征的 2DCNN-S 模型能实现 MFSK 信号的类内识别。

## 2.4 不同条件下卷积神经网络在水声通信信号识别中的应用分析

在水声通信信号数据量充足条件下, 本章设计的基于卷积神经网络的水声通信信号识别算法可以实现 MPSK、OFDM、DSSS 和 MFSK 信号的有效识别, 以及 MPSK 信号和 MFSK 信号的类内识别。

但是在水声通信信号数据量不足条件下, 本章设计的基于卷积神经网络的水声通信信号识别算法识别效果显著下降甚至识别失败。这是因为卷积神经网络模型需要大量的数据进行训练才能保证模型识别的效果, 尤其是各个类别之间的差异性并不是很显著的情况, 例如四类水声通信时序信号及其时频特征、三种 MPSK 信号的时频特征、两种 MFSK 时序信号及其时频特征。但 2FSK 和 4FSK 信号的循环谱特征差异显著, 时域干扰的影响较小, 基于循环谱特征的 2DCNN 模型可以通过少量的训练数据学习到 2FSK 和 4FSK 信号之间的差异, 从而实现 MFSK 信号的类内识别。

针对卷积神经网络实际应用过程中数据量不足的问题, 机器学习算法给出了新的解

决方案,例如通过数据增强算法对样本数据集进行扩充(使用生成对抗网络进行样本生成),通过迁移学习算法将大量样本预训练的模型进行迁移实现对少量样本的分类等等。

由于在实际水声通信侦察过程中往往无法获得充足的水声通信信号数据,基于1DCNN和2DCNN模型的水声通信信号识别技术无法直接应用。本文将在后续章节中研究数据增强以及迁移学习方法,来提高卷积神经网络在数据量不足条件下对水声通信信号的识别效果。

## 2.5 本章小结

本章主要研究了卷积神经网络在水声通信信号识别中的应用分析,采用卷积神经网络模型实现水声通信信号识别,并在不同数据量下进行应用分析。

首先,本章针对四类水声通信信号及其特征设计了水声通信信号类间识别以及MPSK信号和MFSK信号类内识别相结合的水声通信信号识别方案,基于此方案设计了对一维时序信号的1DCNN模型以及针对二维图像特征的2DCNN模型。

其次,本章通过仿真实验验证了方案的可行性,以及卷积神经网络模型的识别效果。仿真实验结果显示,对于MPSK、OFDM、DSSS和MFSK四类水声通信信号的类间识别,基于时频特征的2DCNN模型识别效果优于基于时序信号的1DCNN模型;对于MPSK信号类内识别,基于时频特征的2DCNN模型识别效果最佳,基于循环谱特征的2DCNN模型识别效果最差,这是由于QPSK信号和8PSK信号循环谱特征基本一致,因此对于MPSK信号的类内识别,本文主要研究基于时序信号的1DCNN模型和基于时频特征的2DCNN模型;对于MFSK信号类内识别,基于时频特征的2DCNN模型和基于循环谱特征的2DCNN模型均能准确识别2FSK信号和4FSK信号,且对噪声不敏感。

然后,本章在不同数据量条件下采用松花湖试验数据进行水声通信信号识别研究。试验结果显示,在数据量充足条件下,对于四类水声通信信号类间识别,基于时频特征的2DCNN模型识别效果优于基于时序信号的1DCNN模型;对于MPSK信号的类内识别,基于时频特征的2DCNN模型具有较好的识别效果,但基于时序信号的1DCNN模型识别失败;对于MFSK信号的类内识别,基于时频特征的2DCNN模型和基于循环谱特征的2DCNN模型可以准确识别2FSK信号和4FSK信号,基于时序信号的1DCNN模型识别效果相对较差。在数据量不足条件下,两种算法对四类信号的识别效果显著下降,对MPSK信号的类内识别失败,仅有基于循环谱特征的2DCNN-S模型能准确识别2FSK和4FSK信号。

最后,本章对不同条件下卷积神经网络在水声通信信号识别中的应用进行了分析。



## 第3章 基于数据增强的水声通信信号识别技术

数据增强算法是解决机器学习算法受到数据量不足影响的重要手段，其中的典型算法为生成对抗网络。生成对抗网络由生成器和判别器组成，通过两者之间的对抗博弈学习实际样本分布，生成与之类似的数据，最终实现对数据集的扩充。

在水声通信信号数据量不足条件下，基于卷积神经网络的水声通信信号识别技术在实际应用中受到限制，本章主要研究基于生成对抗网络的数据增强方法，实现在数据量不足条件下的水声通信信号识别。

### 3.1 基于生成对抗网络的水声通信信号数据增强算法研究方案

在水声通信信号数据量不足条件下，为实现 MPSK、OFDM、DSSS 和 MFSK 信号的种类间识别以及 MPSK 信号的类内识别，本章拟采用生成对抗网络分别对四类水声通信信号进行信号增强以及单独对 MPSK 信号进行数据增强，提高水声通信信号识别效果。

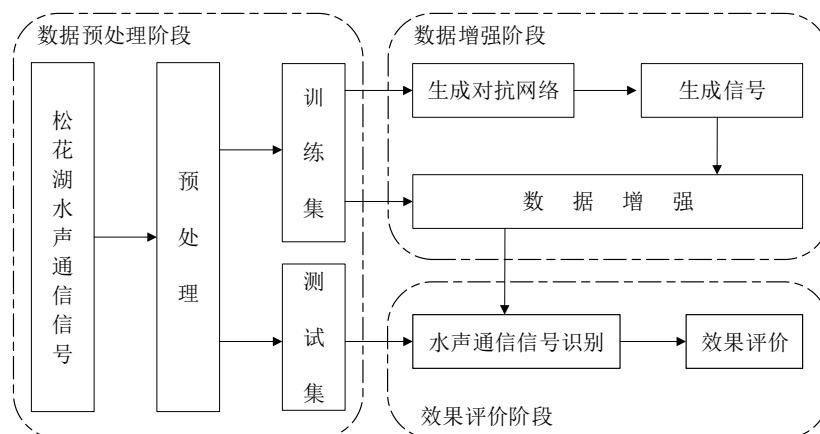


图 3.1 基于生成对抗网络的水声通信信号数据增强算法研究方案

如图 3.1 所示，水声通信信号的数据增强算法研究方案主要包括数据预处理、数据增强和效果评价三个阶段：

#### (1) 数据预处理阶段

将预处理后的松花湖实测水声通信信号，按对不同信号类别标注标签，并随机划分为训练集和测试集。具体数据集采用水声通信信号数据量不足条件下的水声通信信号数据集，预处理方式与水声通信信号识别试验一致。

#### (2) 数据增强阶段

本文选择使用生成对抗网络进行水声通信信号数据增强。原始生成对抗网络的输入

为随机噪声，但是随机噪声与通信信号差异性过大，有可能导致模型无法收敛。因此采用水声通信信号代替随机噪声输入，将松花湖实测水声通信信号作为真实数据，输入到生成对抗网络模型中进行信号生成，然后使用生成的信号进行数据增强。

### (3) 效果评价阶段

使用数据增强后的水声通信信号数据集训练卷积神经网络模型，然后使用该模型对测试集进行水声通信信号识别，与数据量不足条件下的识别效果进行对比，以此评价使用生成对抗网络进行水声通信信号数据增强的效果。

## 3.2 水声通信信号生成对抗网络模型

### 3.2.1 水声通信信号生成对抗网络模型结构设计

为了实现对水声通信信号的生成，本章基于辅助分类生成对抗网络(Auxiliary Classifier GAN, ACGAN)<sup>[47]</sup>设计了水声通信信号生成对抗网络(UWACS-GAN)对松花湖实测水声通信信号进行数据增强研究。如图 3.2 所示，UWACS-GAN 模型使用水声通信信号作为输入，以松花湖实测水声通信信号作为真实数据，以水声通信信号类别作为标签信息，训练 UWACS-GAN 模型，实现水声通信信号数据生成，并使用生成信号对松花湖实测水声通信信号数据集进行数据增强。

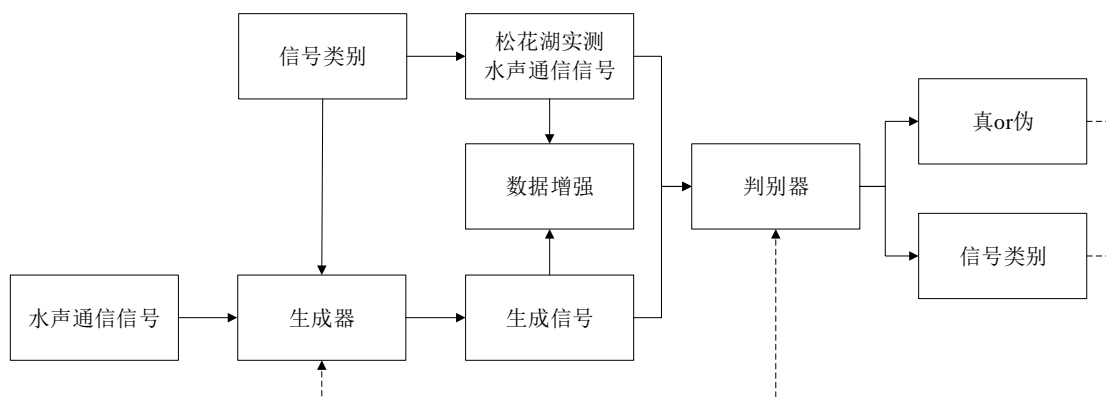


图 3.2 基于 UWACS-GAN 的水声通信信号数据增强算法框图

本章设计的用于水声通信信号数据增强的 UWACS-GAN 模型由生成器模型和判别器模型组成。生成器模型包括 2 个全连接层、2 个重构层、4 个一维上采样层、5 个一维卷积层、4 个批量标准化层，具体结构如图 3.3 所示。其中，输入数据由水声通信信号和对应的标签信息组成；一维卷积层卷积核大小分别为 128/64/32/16/1，大小均为 3，步长均为 1；第二个全连接层和重构层将模型输出数据维度重构为与真实信号维度一致。判别器模型包括 4 个一维卷积层、1 个展平层、1 个全连接层、2 个输出层组成，具体结

构如图 3.4 所示。其中，一维卷积层卷积核大小分别为 16/32/64/128，大小均为 3，步长均为 1；全连接层大小为 512；一个输出层维度为 1，用于判断真伪，另一个输出层维度为信号类别数，用于判断信号类别。训练过程中，为避免模型过拟合，加入 Dropout 层，并将 Dropout 率设置为 0.25。判别器模型卷积层结构与 2.1.2 节中 1DCNN 模型基本一致。此外，UWACS-GAN 模型优化算法采用 Adam 算法。

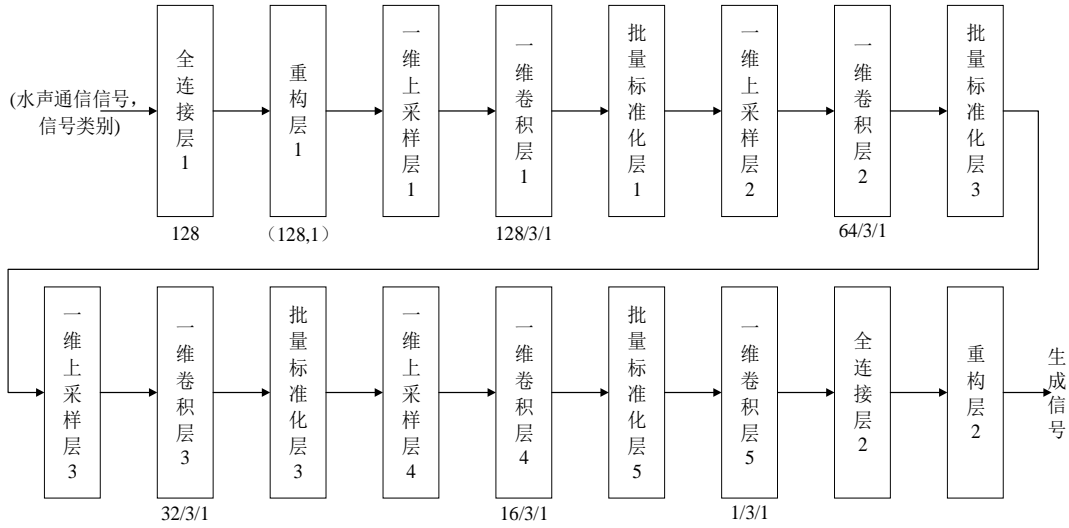


图 3.3 UWACS-GAN 生成器模型结构

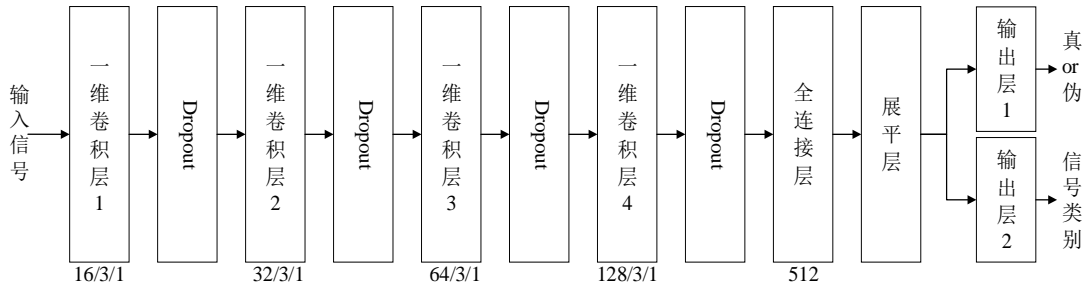


图 3.4 UWACS-GAN 判别器模型结构

### 3.2.2 水声通信信号生成对抗网络模型损失函数

UWACS-GAN 数据增强模型的损失函数与 ACGAN 类似，包含两个部分：对于信号真伪判断的损失函数  $L_C$  和对信号类别判断的损失函数  $L_Y$ 。

$$L_C = E[\log P(C = \text{real} | X_{\text{real}})] + E[\log P(C = \text{fake} | X_{\text{fake}})] \quad (3-1)$$

$$L_Y = E[\log P(Y = y | X_{\text{real}})] + E[\log P(Y = y | X_{\text{fake}})] \quad (3-2)$$

式中， $X_{\text{real}}$  表示真实信号， $X_{\text{fake}} = G(y, s)$  表示生成器生成信号， $y$  表示数据的类别标签， $C = \text{real}$  和  $C = \text{fake}$  表示 D 对于输入信号真假的判别， $Y = y$  表示判别器对于输入信号类别标签的判别。生成器的目的是生成信号样本来欺骗判别器，使得生成器生成的信号



足够逼真,即最大化  $L_Y - L_C$ ; 判断器的目的是最大化对信号真假和类别的判断概率,即最大化  $L_Y + L_C$ 。

### 3.2.3 水声通信信号生成对抗网络模型训练过程

UWACS-GAN 模型训练的目的在于找到生成器和判别器之间的纳什平衡,两者在训练过程中不断对抗,提高生成器的生成能力。通过设置生成器和判别器之间交替训练,先固定生成器 G,训练判别器 D,再固定判别器 D,训练生成器 G,不断循环最终达到模型收敛。UWACS-GAN 数据增强模型训练过程如表 3.1 所示。

表 3.1 UWACS-GAN 数据增强模型训练过程

UWACS-GAN 数据增强模型训练过程	
1	For 迭代次数 do
2	随机从水声通信信号中小批量采样 $\{(s^{(1)}, y_s^{(1)}), \dots, (s^{(m)}, y_s^{(m)})\}$
3	随机从实测水声通信信号中小批量采样 $\{(x^{(1)}, y_x^{(1)}), \dots, (x^{(m)}, y_x^{(m)})\}$
4	计算判别器模型网络梯度: $\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \{\log D(x^{(i)}   y_x^{(i)}) + \log[1 - D(G(s^{(i)}   y_s^{(i)}))]\}$
5	通过 Adam 算法更新判别器网络参数
6	随机从水声通信信号中小批量采样 $\{(s^{(1)}, y_s^{(1)}), \dots, (s^{(m)}, y_s^{(m)})\}$
7	计算生成器模型网络梯度: $\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \{\log D(G(s^{(i)}   y_s^{(i)})) + \log D(y   G(s^{(i)}   y_s^{(i)}))\}$
8	通过 Adam 算法更新生成器网络参数
9	End for

### 3.2.4 水声通信信号生成对抗网络模型生成信号分析

与传统 GAN 相比,本文设计的 UWACS-GAN 中的判别器模型不仅能判断输入信号的真伪,也可以判断输入信号的类别。本节将 UWACS-GAN 的判别器模型提取出来,作为分类模型,对松花湖水声通信信号进行识别,以此为依据对生成信号与实测信号之间的相似性进行分析。

## 3.2.4.1 四类水声通信生成信号分析

使用水声通信信号数据增强 UWACS-GAN 模型的判别器对 2.3.2 节中水声通信信号数据量不足条件下水声通信信号类间识别数据集 IV 的测试集进行水声通信信号类间识别, 判别器模型对四类水声通信信号识别准确率为 71.42%, 其混淆矩阵如图 3.5 所示。计算 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值, 结果如表 3.2 所示。




图 3.5 水声通信信号判别器模型识别结果混淆矩阵

表 3.2 水声通信信号类间识别结果评价指标

类间识别 模型	MPSK			OFDM		
	P	R	F1	P	R	F1
1DCNN-S	56.54%	76.33%	64.96%	59.43%	49.33%	53.91%
判别器	66.79%	59.00%	62.65%	70.12%	58.67%	63.88%
类间识别 模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN-S	57.20%	42.33%	48.66%	78.70%	85.00%	81.73%
判别器	60.95%	68.67%	64.58%	86.13%	99.33%	92.26%

上述结果表明, 经过 UWACS-GAN 的训练, 判别器模型的识别准确率比数据量不足条件下的 1DCNN-S 模型的识别准确率(63.24%)提高 8.18 个百分点, 除 MPSK 信号的识别效果下降, OFDM、DSSS 和 MFSK 信号的识别效果均有提升; 判别器模型识别结果中 MPSK 信号的 F1 值下降 2.31 个百分点, 但 OFDM、DSSS 和 MFSK 信号的 F1 值上升 10 个百分点左右, 特别是 DSSS 信号上升 15.92 个百分点。判别器模型和 1DCNN-S 模型结构基本一致, 但识别效果有所提升, 这可能是因为判别器模型在 UWACS-GAN 的训练过程中通过与生成器模型之间的对抗, 学习到了水声通信信号的深度特征, 提升

了数据量不足条件下的水声通信信号识别效果，说明 UWACS-GAN 生成信号与实测水声通信信号之间具有一定的相似性。

### 3.2.4.1 水声通信 MPSK 生成信号分析

使用水声通信 MPSK 信号数据增强 UWACS-GAN 模型的判别器对 2.3.2 节中水声通信信号数据量不足条件下水声通信 MSPK 信号类内识别数据集V的测试集进行水声通信 MPSK 信号类内识别,判别器模型对 BPSK、QPSK 和 8PSK 信号识别准确率为 37.00%，其混淆矩阵如图 3.6 所示。计算 BPSK、QPSK 和 8PSK 信号的精确率、召回率和 F1 值，结果如表 3.3 所示。




图 3.6 水声通信 MPSK 信号判别器模型识别结果混淆矩阵

表 3.3 水声通信 MPSK 信号识别结果评价指标

MPSK 类内 识别模型	BPSK			QPSK		
	P	R	F1	P	R	F1
1DCNN-S	37.04%	40.00%	38.46%	31.40%	27.00%	29.03%
判别器	38.79%	45.00%	41.67%	38.37%	33.00%	35.48%
MPSK 类内 识别模型	8PSK					
	P	R	F1			
1DCNN-S	40.57%	43.00%	41.75%			
判别器	33.67%	33.00%	33.33%			

上述结果表明，经过 UWACS-GAN 的训练，判别器模型仍然无法识别三类信号，这是因为三类信号之间的主要差异在于相位信息，基于时序信号的识别方法无法提取相位相关的特征。

综上所述，在水声通信信号数据量不足条件下，经过 UWACS-GAN 的训练，与 1DCNN-S 模型的识别效果相比，判别器模型一定程度上提升了水声通信信号识别效果，

表明 UWACS-GAN 生成信号与实测水声通信信号之间具有较好的相似性，可以用于数据增强。

### 3.3 水声通信信号数据增强效果评价试验

在水声通信信号数据量不足条件下，通过将 UWACS-GAN 的生成信号加入水声通信信号识别数据集的训练集中，构成水声通信信号识别数据增强训练集，训练水声通信信号数据增强识别模型(CNN-DA 模型)，同时使用加入等量仿真信号的水声通信信号仿真训练集训练 CNN-FZ 模型，并对两个模型在相同测试集下的识别结果进行对比，从而对 UWACS-GAN 数据增强效果进行评价，具体试验流程如图 3.7 所示。

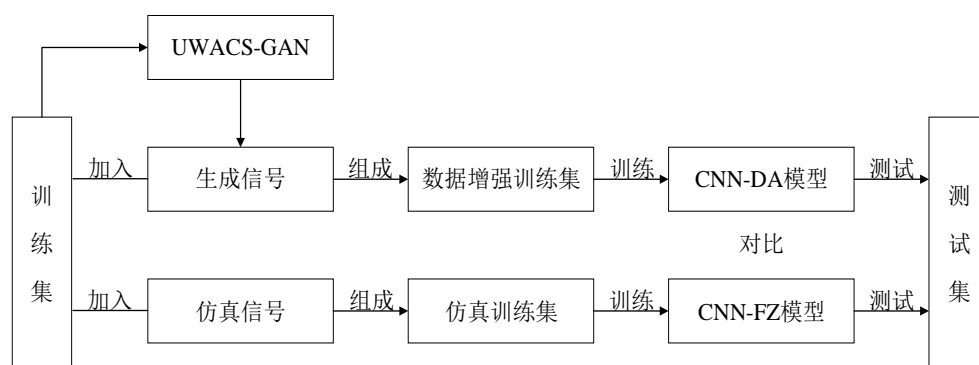


图 3.7 数据增强效果评价试验流程

#### 3.3.1 水声通信信号类间识别数据增强效果评价试验

水声通信信号类间识别数据增强试验数据集设置如表 3.4 所示。其中，数据增强训练集规模与数据量充足条件下的训练集相同，即数据增强训练集包含 20%的松花湖水声通信实测信号和 80%的生成信号，仿真训练集则是通过加入等量信噪比为 8dB 的仿真信号的仿真训练集组成，即仿真训练集包含 20%的松花湖实测水声通信信号和 80%的水声通信仿真信号。分别使用数据增强训练集和仿真训练集训练 CNN-DA 模型和 CNN-FZ 模型，对同一测试集进行识别，对数据增强效果进行对比分析。

表 3.4 水声通信信号类间识别数据增强试验数据集设置

信号类型	MPSK、OFDM、DSSS、MFSK
基础训练集	每类各 1200 个实测水声通信信号样本
仿真训练集	基础训练集中加入每类各 4800 个仿真信号样本
数据增强训练集	基础训练集中加入每类各 4800 个生成信号样本
测试集	每类各 300 个实测水声通信信号样本

### 3.3.1.1 基于时序信号的数据增强效果分析

使用基于时序信号的 1DCNN 模型进行数据增强效果分析，分别采用数据增强训练集和仿真训练集训练 1DCNN-DA 模型和 1DCNN-FZ 模型，对同一测试集进行识别，两个模型的识别准确率分别为 77.13%和 72.41%，识别结果混淆矩阵如图 3.8 所示，根据混淆矩阵计算 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值结果如表 3.5 所示，并绘制各类信号评价指标的对比如图 3.9 所示。




图 3.8 水声通信信号类间识别结果混淆矩阵

表 3.5 水声通信信号类间识别结果评价指标

类间识别模型	MPSK			OFDM		
	P	R	F1	P	R	F1
1DCNN-S	56.54%	76.33%	64.96%	59.43%	49.33%	53.91%
1DCNN-FZ	60.34%	81.67%	69.41%	74.23%	64.33%	68.93%
1DCNN-DA	70.71%	79.67%	<b>74.92%</b>	73.20%	71.00%	<b>72.08%</b>
1DCNN	72.56%	98.65%	83.62%	96.35%	71.10%	81.82%
类间识别模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN-S	57.20%	42.33%	48.66%	78.70%	85.00%	81.73%
1DCNN-FZ	79.44%	47.67%	59.58%	75.59%	96.00%	84.58%
1DCNN-DA	72.73%	61.33%	<b>66.55%</b>	88.53%	96.50%	<b>92.34%</b>
1DCNN	77.19%	69.90%	73.36%	98.49%	98.00%	98.25%

结果表明，在水声通信信号数据量不足条件下，基于 UWACS-GAN 的水声通信信号数据增强算法可以更加有效地提高水声通信信号的识别效果。相比 1DCNN-S 模型(识

别准确率为 63.24%), 1DCNN-FZ 模型识别准确率上升 9.17 个百分点, 1DCNN-DA 模型识别准确率上升 13.89 个百分点, 1DCNN-DA 模型的识别准确率比 1DCNN-FZ 模型高 4.72 个百分点; 综合三个评价指标, 相比 1DCNN-S 模型, 1DCNN-FZ 模型和 1DCNN-DA 模型对四类信号的识别效果均有不同程度的提升, 尤其是 OFDM 和 DSSS 信号识别效果显著提升。




图 3.9 水声通信信号类间识别结果评价指标对比

综上所述, 在水声通信信号数据量不足条件下, 基于 UWACS-GAN 生成信号的数据增强算法可以更加有效地提高水声通信信号识别效果, UWACS-GAN 的生成信号能够有效进行数据集扩充。

### 3.3.1.2 基于时频特征的数据增强效果分析

通过小波变换提取数据增强训练集以及仿真训练集中的 MPSK、OFDM、DSSS 和 MFSK 信号的时频特征, 分别训练 2DCNN-DA 以及 2DCNN-FZ 模型, 对同一测试集进行识别, 两个模型的识别准确率分别为 73.17%和 67.25%, 识别结果混淆矩阵如图 3.10 所示, 根据混淆矩阵计算 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值结果如表 3.6 所示, 绘制各类信号评价指标的对比如图 3.11 所示。

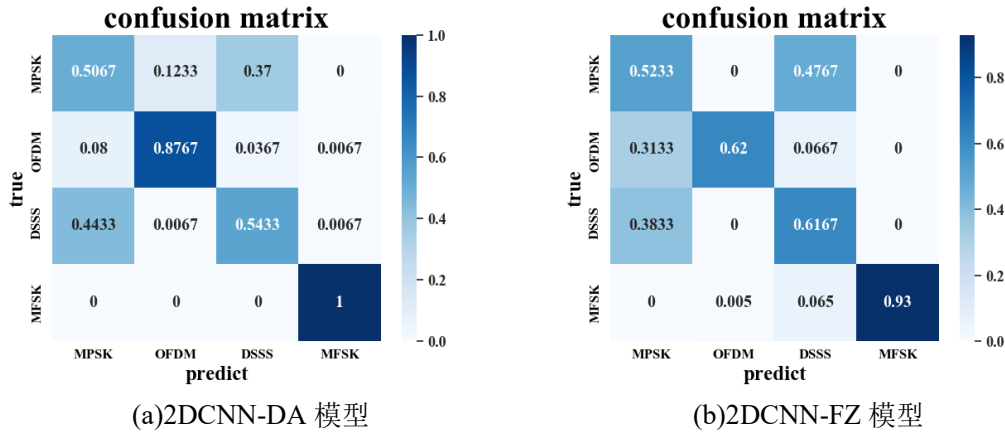


图 3.10 水声通信信号类间识别结果混淆矩阵

表 3.6 水声通信信号类间识别结果评价指标

类间识别模型	MPSK			OFDM		
	P	R	F1	P	R	F1
2DCNN-S	46.49%	25.33%	32.79%	54.80%	44.67%	49.22%
2DCNN-FZ	42.90%	52.33%	47.15%	99.47%	62.00%	76.39%
2DCNN-DA	49.19%	50.67%	<b>49.92%</b>	87.08%	87.67%	<b>87.38%</b>
2DCNN	90.15%	79.33%	84.39%	99.84%	97.08%	98.44%
类间识别模型	DSSS			MFSK		
	P	R	F1	P	R	F1
2DCNN-S	51.24%	69.00%	58.81%	66.50%	86.00%	75.00%
2DCNN-FZ	51.25%	61.67%	<b>55.98%</b>	100.00%	93.00%	96.37%
2DCNN-DA	57.19%	54.33%	55.73%	98.04%	100.00%	<b>99.01%</b>
2DCNN	80.86%	92.92%	86.47%	99.58%	99.42%	99.50%

结果表明，在水声通信信号数据量不足条件下，基于 UWACS-GAN 的水声通信信号数据增强算法可以更加有效地提高水声通信信号的识别效果。相比 2DCNN-S 模型(识别准确率为 56.25%)，2DCNN-DA 模型的识别准确率上升 16.92 个百分点，2DCNN-FZ 模型的识别准确率上升 11.00 个百分点，2DCNN-DA 模型识别准确率比 2DCNN-FZ 模型高 5.92 个百分点；综合三个评价指标，相比 2DCNN-S 模型，2DCNN-FZ 和 2DCNN-DA 模型对 MPSK、OFDM 和 MFSK 信号的识别效果均有不同程度的提升，两个模型对 MFSK 信号的识别效果接近数据量充足条件下的 2DCNN 模型，但对 DSSS 信号的识别效果相比 2DCNN-S 模型略微下降，这是因为两个模型对 MPSK 和 DSSS 信号的识别混

淆严重。




图 3.11 水声通信信号类间识别结果评价指标对比

综上所述,在水声通信信号数据量不足条件下,基于 UWACS-GAN 的数据增强算法可以更加有效地提高基于时频特征的水声通信信号类间识别效果,表明 UWACS-GAN 的生成信号能够有效进行数据集扩充。

### 3.3.1.3 水声通信信号类间识别数据增强效果对比

本节从准确率和宏 F1 值两个角度对比数据量充足条件下的水声通信信号识别模型、数据量不足条件下的水声通信信号识别模型以及数据增强后的水声通信信号识别模型,结果如图 3.12 所示。

结果表明,在水声通信信号数据量不足条件下,通过加入仿真信号或 UWACS-GAN 的生成水声通信信号进行数据增强,均能提高水声通信信号类间识别的效果;基于时序信号的数据增强识别算法对四类水声通信信号的识别效果优于基于时频特征的数据增强识别算法,但是在数据量充足条件下,基于时频特征的 2DCNN 模型识别效果优于基于时序信号的 1DCNN 模型,这可能是因为相比时序特征,时频特征更加复杂,CNN 模型需要更多实测数据进行学习;基于 UWACS-GAN 生成信号的数据增强算法可以从训



练中学习到与实测数据类似分布的特征, 试验结果表明, 通过加入 UWACS-GAN 的生成信号, 在水声通信信号类间识别中可以有效地起到扩充数据集的作用, 且其效果略优于使用仿真信号进行数据集扩充时的效果。




图 3.12 水声通信信号类间识别结果对比

### 3.3.2 水声通信 MPSK 信号类内识别数据增强效果评价试验

水声通信 MPSK 信号类内识别数据增强试验数据集设置如表 3.7 所示。其中, 数据增强训练集规模与数据量充足条件下相同, 即数据增强训练集包含 20%的松花湖水声通信实测信号和 80%的生成信号, 仿真训练集则是加入等量信噪比为 8dB 的仿真信号的仿真训练集组成, 即仿真训练集包含 20%的松花湖实测水声通信信号和 80%的水声通信仿真信号。然后分别使用数据增强训练集和仿真训练集训练 CNN-DA 模型和 CNN-FZ 模型, 对同一测试集进行识别, 通过对比识别结果对数据增强效果进行分析。

表 3.7 水声通信 MPSK 信号类内识别数据增强试验数据集设置

信号类型	BPSK、QPSK、8PSK
基础训练集	每种各 400 个实测水声通信信号样本
仿真训练集	基础训练集中加入每种各 1600 个仿真信号样本
数据增强训练集	基础训练集中加入每种各 1600 个生成信号样本
测试集	每种各 100 个实测水声通信信号样本

#### 3.3.2.1 基于水声通信 MPSK 时序信号的数据增强效果分析

使用基于时序信号的 1DCNN 模型进行数据增强效果分析, 分别采用数据增强训练集和仿真训练集训练 1DCNN-DA 模型和 1DCNN-FZ 模型, 对同一测试集进行识别, 两个模型的识别准确率分别为 38.33%和 37.67%, 得到的水声通信 MPSK 信号类内识别结

果混淆矩阵如图 3.13 所示。




图 3.13 水声通信 MPSK 信号数据增强效果分析

结果表明，通过加入仿真信号或 UWACS-GAN 生成信号进行数据增强仍然无法实现基于时序信号的水声通信 MPSK 信号类内识别。

### 3.3.2.2 基于水声通信 MPSK 信号时频特征的数据增强效果分析

采用小波变换对数据增强训练集以及仿真训练集中的 BPSK、QPSK 和 8PSK 信号提取时频特征，分别训练 2DCNN-DA 和 2DCNN-FZ 模型，对同一测试集进行识别，两个模型的识别准确率分别为 84.67%和 82.67%，识别结果混淆矩阵如图 3.14 所示。根据混淆矩阵计算 BPSK、QPSK 和 8PSK 信号的精确率、召回率和 F1 值如表 3.8 所示，并绘制 MPSK 信号类内识别结果评价指标对比如图 3.15 所示。




图 3.14 MPSK 信号识别结果混淆矩阵

结果表明，在水声通信信号数据量不足条件下，通过加入水声通信仿真信号和 UWACS-GAN 生成信号进行数据增强，可以有效提高基于时频特征的水声通信 MPSK 信号类内识别效果。2DCNN-DA 模型和 2DCNN-FZ 模型的识别准确率分别为 84.67%和 82.67%，2DCNN-DA 模型识别准确率比 2DCNN-FZ 模型高 2.00 个百分点；与 2DCNN-S 模型相比，2DCNN-FZ 模型的综合评价指标上升 36 个百分点左右，2DCNN-DA 模型的综合评价指标上升 38 个百分点左右；与数据量充足条件下的 2DCNN 模型相比，2DCNN-FZ 模型的综合评价指标低 7 个百分点左右，2DCNN-DA 模型的识别准确率低


5 个百分点左右。

表 3.8 MPSK 信号类间识别结果混淆矩阵


MPSK 信号 类内识别模型	BPSK			QPSK		
	P	R	F1	P	R	F1
2DCNN-S	44.44%	44.00%	44.22%	52.53%	52.00%	52.26%
2DCNN-FZ	85.42%	82.00%	83.67%	84.62%	77.00%	80.63%
2DCNN-DA	85.85%	85.00%	<b>85.43%</b>	78.26%	90.00%	<b>83.72%</b>
2DCNN	93.82%	88.66%	91.17%	90.86%	87.83%	89.32%


MPSK 信号 类内识别模型	8PSK			综合指标		
	P	R	F1	Marco-P	Marco-R	Marco-F1
2DCNN-S	42.16%	43.00%	42.57%	46.38%	46.33%	46.35%
2DCNN-FZ	78.76%	89.00%	83.57%	82.93%	82.67%	82.62%
2DCNN-DA	91.86%	79.00%	<b>84.95%</b>	85.32%	84.67%	<b>84.70%</b>
2DCNN	85.60%	93.16%	89.22%	90.09%	89.88%	89.90%




(a)BPSK 信号评价指标



(b)QPSK 信号评价指标



(c)8PSK 信号评价指标



(d)综合评价指标

图 3.15 MPSK 信号识别结果评价指标对比

综上所述,在水声通信信号不足条件下,基于时频特征的数据增强 MPSK 信号类内识别算法识别效果优于基于时序信号的数据增强 MPSK 信号类内识别算法,这是因为时频分析能够更好地体现 MPSK 信号之间的差异。

### 3.4 本章小结

本章研究了基于数据增强的水声通信信号识别技术,有效提高了数据量不足条件下的水声通信信号识别效果。

首先,本章提出了基于生成对抗网络的水声通信信号数据增强方案,并设计了 UWACS-GAN 模型,介绍了其中生成器和判别器模型结构及其训练流程,提取 UWACS-GAN 判别器模型,对水声通信信号进行识别。试验结果显示, UWACS-GAN 生成信号可以用于数据增强。

然后,本章使用 UWACS-GAN 模型对 MPSK、OFDM、DSSS 和 MFSK 四类水声通信信号进行数据增强,均能有效提高基于时域特征和时频特征的水声通信信号类间识别效果,基于时序信号的 1DCNN 算法识别效果略优于基于时频特征的 2DCNN 算法,基于 UWACS-GAN 生成信号的数据增强效果略优于基于仿真信号的数据增强效果。

最后,本章使用 UWACS-GAN 模型对水声通信 MPSK 信号进行数据增强,提高了基于时频特征的 MPSK 信号类内识别效果,基于 UWACS-GAN 生成信号的数据增强效果略优于基于仿真信号的数据增强效果。

通过上述研究结果可以看出,相比使用仿真信号扩充的数据集,使用本章设计的 UWACS-GAN 模型的生成信号扩充的数据集可以训练更为准确的水声通信信号识别模型。由试验结果可知,在实际的调制模式识别应用过程中,如果无法依靠足够精细的水下声场环境信息构造仿真信号时,基于生成对抗网络的方式可以作为一种有效的替代方式实现数据集的扩充。



## 第4章 基于迁移学习的水声通信信号识别技术

迁移学习算法是机器学习领域解决数据量不足条件下的样本分类问题的重要方法之一。迁移学习通过将大量源域数据预训练的分类模型进行迁移,实现对少量目标域样本的分类识别。

在水声通信信号数据量不足条件下,卷积神经网络无法直接应用于水声通信侦察,经过基于 UWACS-GAN 的数据增强后水声通信信号识别效果与数据量充足条件下仍有一定差距。为了进一步提高水声通信信号识别效果,本章采用基于卷积神经网络的迁移学习算法开展水声通信信号识别技术研究。

### 4.1 基于卷积神经网络的迁移学习方法及策略

基于卷积神经网络的迁移学习是通过将源域大量有标签数据预训练的源域卷积神经网络模型的全部或部分网络权重或结构迁移到目标域卷积神经网络模型中,从而实现与源域数据分布相同或类似的少量目标域数据的分类识别,如图 4.1 所示。

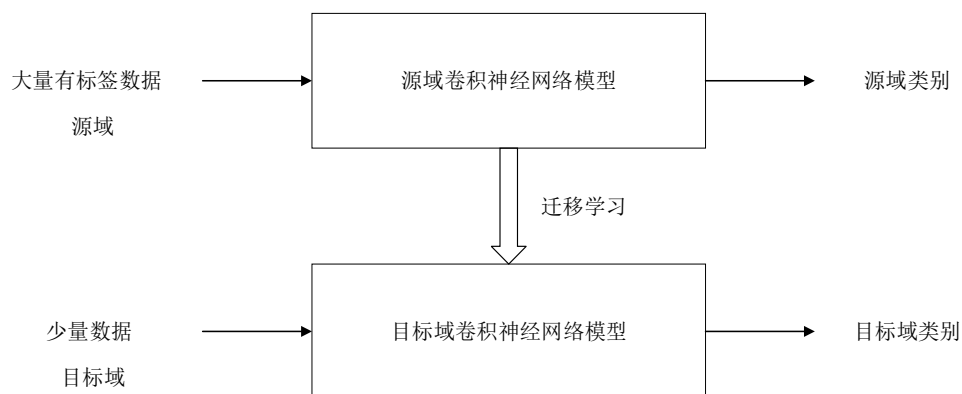


图 4.1 基于卷积神经网络的迁移学习方法

基于卷积神经网络的迁移学习针对不同的数据集,具有不同的迁移学习策略:

(1)针对具有大量数据的数据集,采用重新训练卷积神经网络模型或者冻结少部分卷积层训练大部分网络层的方式进行迁移学习;

(2)针对具有少量数据的数据集,采用冻结大部分或者全部卷积层,重新训练剩下的网络层,或者采用参数微调的方式进行迁移学习。

以本文设计的四层卷积层的卷积神经网络模型为例,不同条件下的迁移学习策略如图 4.2 所示。

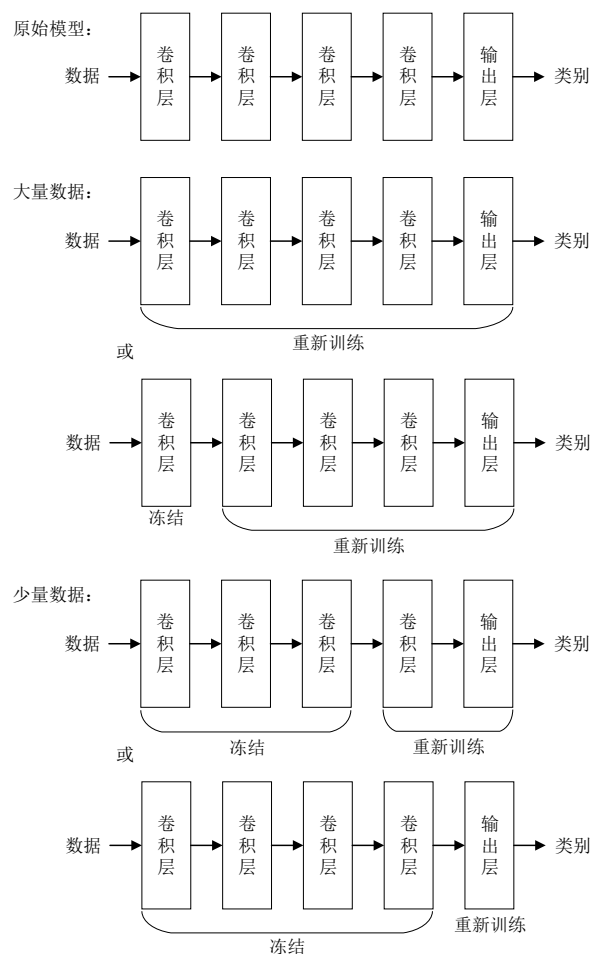


图 4.2 不同条件下的迁移学习策略

## 4.2 基于卷积神经网络的水声通信信号识别迁移学习方案

实测水声通信信号获取困难，可以作为迁移学习中少量数据的目标域，通过仿真获得的大量水声通信仿真信号，或者通过 UWACS-GAN 生成的大量水声通信信号，可以作为迁移学习中大量有标签数据的源域。在此基础上，本节设计了基于卷积神经网络的水声通信信号识别迁移学习方案，如图 4.3 所示。

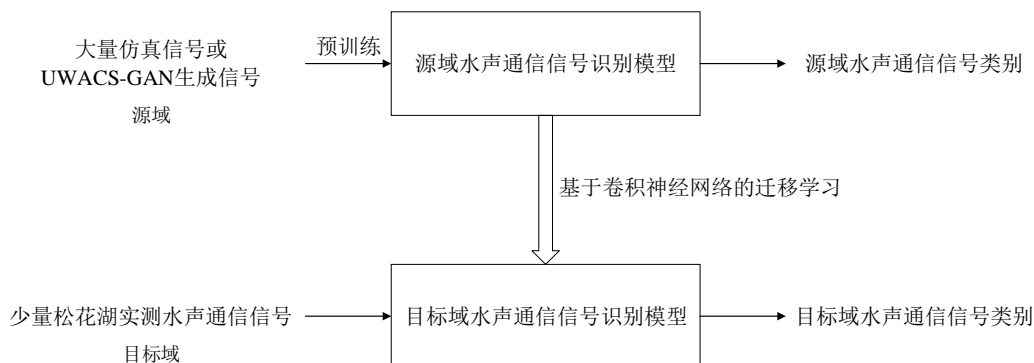


图 4.3 基于卷积神经网络的水声通信信号识别迁移学习方案

水声通信仿真信号和第3章中 UWACS-GAN 生成的水声通信信号与实测水声通信信号之间存在一定的差异性,本章选择冻结部分预训练卷积神经网络的卷积层结构和参数,对剩余层进行参数微调的方式进行基于迁移学习的水声通信信号识别,具体迁移学习策略如图4.4所示。

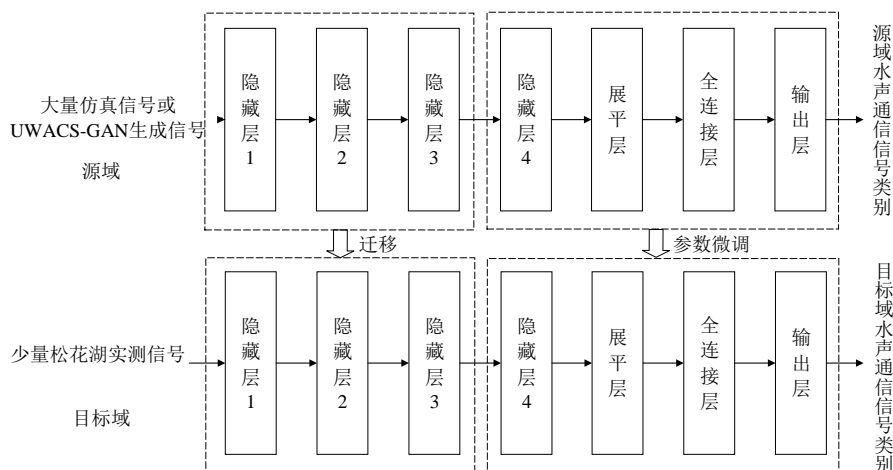


图 4.4 基于迁移学习的水声通信信号识别策略

基于迁移学习的水声通信信号识别技术通过冻结预训练水声通信信号识别卷积神经网络的前三个隐藏层,使用训练集微调最后一个隐藏层以及剩余网络层参数的方式进行基于卷积神经网络的迁移学习,最终实现对测试集水声通信信号的识别。

### 4.3 基于迁移学习的水声通信信号识别试验

基于迁移学习的水声通信信号识别试验将分别以松花湖水声通信仿真信号以及 UWACS-GAN 生成信号为源域,以少量松花湖实测水声通信信号为目标域,研究基于迁移学习的水声通信信号识别技术。

#### 4.3.1 基于仿真信号识别模型迁移的水声通信信号识别试验

##### 4.3.1.1 基于仿真信号识别模型迁移的水声通信信号类间识别试验

试验针对 2.3.2 节中的水声通信信号数据量不足条件下的水声通信信号类间识别数据集IV,在 2.2.3 节中基于时序信号的 1DCNN 仿真模型和基于时频特征的 2DCNN 仿真模型的基础上进行参数微调,实现基于仿真信号识别模型迁移的水声通信信号类间识别,两个模型迁移后的识别准确率分别为 81.17%和 89.17%,其测试集混淆矩阵如图 4.5 所示,将两个迁移后的模型分别记为 1DCNN-TL 和 2DCNN-TL。根据混淆矩阵计算得到 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值结果如表 4.1 所示,并和表 2.8 以及表 2.12 进行对比,得到结果如图 4.6 所示。






图 4.5 基于仿真信号识别模型迁移学习的识别结果混淆矩阵

表 4.1 基于仿真信号类间识别模型的迁移学习识别结果评价指标

类间识别模型	MP/K			OFDM		
	P	R	F1	P	R	F1
1DCNN-TL	99.01%	67.33%	80.15%	82.73%	84.67%	83.69%
2DCNN-TL	72.82%	97.33%	83.31%	99.63%	88.00%	93.45%

类间识别模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN-TL	99.55%	72.66%	84.00%	63.83%	100.0%	77.92%
2DCNN-TL	72.77%	71.34%	72.05%	96.15%	100.0%	98.04%




图 4.6 不同条件下水声通信信号类间识别算法评价指标对比

结果表明,在水声通信信号数据量不足条件下,通过基于仿真信号识别模型的迁移学习,可以有效提高水声通信信号类间识别效果,接近数据量充足条件下的识别效果;其中,1DCNN-TL模型的识别准确率与1DCNN-S模型的识别准确率(63.24%)相比上升17.93个百分点,但与1DCNN模型的识别准确率(84.43%)相比仅低3.26个百分点;2DCNN-TL模型的识别准确率与2DCNN-S模型的识别准确率(56.25%)相比上升32.92个百分点,但与2DCNN模型的识别准确率(92.19%)相比仅低3.02个百分点;基于时序信号的1DCNN-TL模型将20%左右的MPSK、OFDM和DSSS信号被误判为MFSK信号,对MFSK信号识别效果欠佳。

#### 4.3.1.2 基于仿真信号识别模型迁移的MPSK信号类内识别结果

针对3.3.2节中水声通信信号数据量不足条件下的MPSK信号类内识别数据集V,在3.5.5节中基于时序信号的1DCNN仿真模型和基于时频特征的2DCNN仿真模型的基础上进行参数微调,实现基于仿真模型迁移的MPSK信号类内识别,两个模型迁移学习后的识别准确率分别为38.00%和85.67%,识别结果混淆矩阵如图4.7所示,将两个迁移后的模型分别记为1DCNN-TL和2DCNN-TL。进一步计算得到BPSK、QPSK和8PSK信号的精确率、召回率和F1值结果如表4.2所示,并将结果与表2.9和表2.15进行对比,得到结果如图4.8所示。




图 4.7 基于仿真信号识别模型迁移的 MPSK 信号类内识别结果混淆矩阵

表 4.2 基于仿真信号识别模型迁移的 MPSK 信号类内识别结果评价指标

MPSK 信号	1DCNN-TL 模型			2DCNN-TL 模型		
	P	R	F1	P	R	F1
BPSK	35.11%	46.00%	39.83%	100.00%	74.00%	85.06%
QPSK	42.65%	29.00%	34.52%	89.58%	86.00%	87.76%
8PSK	38.61%	39.00%	38.81%	74.61%	97.00%	84.35%




图 4.8 不同条件下 MPSK 信号类内识别算法评价指标对比

结果表明,在水声通信信号数据量不足条件下,通过基于仿真信号识别模型的迁移学习方法,基于时序信号的 1DCNN-TL 模型仍无法识别 MPSK 信号,基于时频特征的 2DCNN-TL 模型能有效提高 MPSK 信号的类内识别效果,与 2DCNN 模型的识别准确率相比仅低 4.22 个百分点。

### 4.3.2 基于生成信号识别模型迁移的水声通信信号识别试验

使用 UWACS-GAN 生成的水声通信信号预训练基于时序信号的 1DCNN 模型和基于时频特征的 2DCNN 模型,然后将模型迁移到松花湖实测水声通信信号识别模型上,开展基于生成信号识别模型迁移的水声通信信号识别研究,其中预训练模型使用生成信号的数据量均与数据量充足条件下一致。

#### 4.3.2.1 基于生成信号识别模型迁移的水声通信信号类间识别试验

针对 2.3.2 节中的水声通信信号数据量不足条件下的水声通信信号类间识别数据集 IV,使用 UWACS-GAN 生成信号预训练基于时序信号的 1DCNN 识别模型和基于时频特征的 2DCNN 识别模型,两个模型迁移后的识别准确率分别为 83.92%和 91.42%,混淆矩阵如图 4.9 所示,其中,将两个迁移后的模型分别记为 1DCNN-GTL 和 2DCNN-

GTL。根据混淆矩阵计算得到 MPSK、OFDM、DSSS 和 MFSK 信号的精确率、召回率和 F1 值结果如表 4.3 所示, 并和表 2.8 以及表 2.12 进行对比, 得到结果如图 4.10 所示。

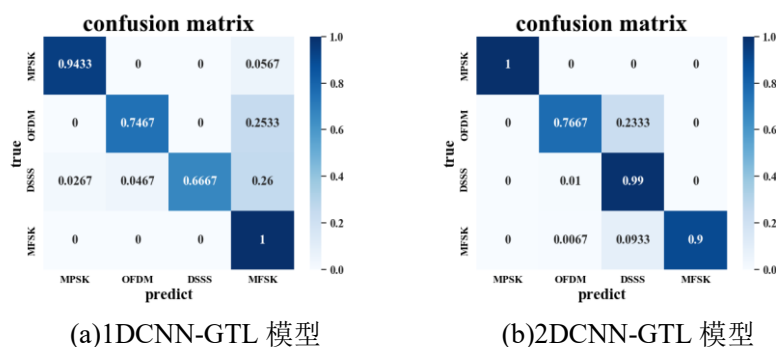


图 4.9 基于生成信号识别模型的迁移学习识别结果混淆矩阵

表 4.3 基于生成信号类间识别模型的迁移学习识别结果评价指标

类间识别模型	MPSK			OFDM		
	P	R	F1	P	R	F1
1DCNN-GTL	97.25%	94.33%	95.77%	94.11%	74.67%	83.27%
2DCNN-GTL	100.00%	100.00%	100.00%	97.87%	76.67%	85.98%
类间识别模型	DSSS			MFSK		
	P	R	F1	P	R	F1
1DCNN-GTL	100.00%	66.67%	80.00%	63.69%	100.00%	77.82%
2DCNN-GTL	75.19%	99.00%	85.47%	100.00%	90.00%	94.74%

结果表明, 在水声通信信号数据量不足条件下, 基于生成信号识别模型的迁移学习方法可以有效提高水声通信信号类间识别效果, 甚至接近数据量充足条件下的识别效果; 1DCNN-GTL 模型和 2DCNN-GTL 模型的识别准确率分别为 83.92% 和 91.42%, 与数据量充足条件下的 1DCNN 模型(84.43%)和 2DCNN 模型(92.19%)相比仅低不到 1 个百分点; 1DCNN-GTL 模型对 MPSK、OFDM 和 DSSS 信号的识别效果要优于 1DCNN 模型对三者的识别效果, 但 1DCNN-GTL 模型将超过 25% 的 OFDM 和 DSSS 信号误判为 MFSK 信号, 这个结果与 1DCNN-TL 模型识别结果类似; 2DCNN-GTL 模型对 MPSK 信号的识别效果优于 2DCNN 模型的识别效果, 但是超过 20% 的 OFDM 信号被误判为 DSSS 信号, 这导致 2DCNN-GTL 模型对 OFDM 信号识别效果低于 2DCNN 模型。




图 4.10 不同条件下水声通信信号类间识别算法评价指标对比

#### 4.3.2.2 基于生成信号识别模型迁移的水声通信 MPSK 信号类内识别试验

针对 3.3.2 节中数据量不足条件下的 MPSK 信号类内识别数据集 V，使用 UWACS-GAN 的 MPSK 生成信号预训练基于时序信号的 1DCNN 识别模型和基于时频特征的 2DCNN 识别模型，两个模型经过迁移后的识别准确率分别为 42.33% 和 86.00%，其测试集混淆矩阵如图 4.11 所示，分别将两个迁移后的模型记为 1DCNN-GTL 和 2DCNN-GTL。进一步计算得到 BPSK、QPSK 和 8PSK 信号的精确率、召回率和 F1 值结果如表 4.4 所示，并将结果与表 2.9 和表 2.15 进行对比，得到结果如图 4.12 所示。




图 4.11 基于生成信号识别模型迁移的 MPSK 信号类内识别结果混淆矩阵

表 4.4 基于生成信号识别模型迁移的 MPSK 信号类内识别结果评价指标

MPSK 信号 类内识别模型	1DCNN-GTL 模型			2DCNN-GTL 模型		
	P	R	F1	P	R	F1
BPSK	44.76%	47.00%	45.85%	86.79%	92.00%	89.32%
QPSK	39.19%	29.00%	33.33%	82.73%	91.00%	86.67%
8PSK	42.15%	51.00%	46.15%	89.29%	75.00%	81.52%

结果表明,在水声通信信号数据量不足条件下,基于时序信号的 1DCNN-GTL 模型对 MPSK 信号的类内识别仍然失败;基于时频特征的 2DCNN-GTL 模型对 BPSK、QPSK 和 8PSK 信号的识别效果显著提升,与数据量充足条件下的 2DCNN 模型(识别准确率为 89.89%)相比仅低 3.89 个百分点,但该模型对 8PSK 信号的识别效果相对较差。




图 4.12 不同条件下 MPSK 信号类内识别算法评价指标对比

#### 4.4 水声通信信号识别算法综合对比

在水声通信信号数据量不足条件下,对本文所提出的水声通信信号识别算法进行对

比, 包括基于 UWACS-GAN 的水声通信信号识别算法(UWACS-GAN 的判别器)、基于数据增强的水声通信信号识别算法(基于仿真信号增强的 1DCNN-FZ 及 2DCNN-FZ 和基于生成信号增强的 1DCNN-DA 及 2DCNN-DA)和基于迁移学习的水声通信信号识别算法(基于仿真信号识别模型迁移的 1DCNN-TL 及 2DCNN-TL 和基于生成信号识别模型迁移的 1DCNN-GTL 及 2DCNN-GTL)。分别从水声通信信号识别结果的准确率和宏 F1 值两个方面, 对比数据量充足以及数据量不足条件下的水声通信信号识别结果, 从而确定数据量不足条件下的水声通信信号识别方案。

#### 4.4.1 水声通信信号类间识别算法综合对比

在水声通信信号数据量不足条件下, 将本文所提出的所有水声通信信号类间识别算法识别结果的准确率和宏 F1 值作为综合评价指标进行统计, 结果如表 4.5 所示。综合评价指标对比如图 4.13 所示, 其中图 4.13(a)为基于时序信号的水声通信信号类间识别 1DCNN 相关模型综合评价指标对比, 图 4.13(b)为基于时频特征的水声通信信号类间识别 2DCNN 相关模型综合评价指标对比。

表 4.5 不同条件下水声通信信号类间识别模型综合评价指标对比

条件	模型	准确率	宏 F1 值
数据量不足	1DCNN-S	63.24%	62.32%
	2DCNN-S	56.25%	53.96%
UWACS-GAN	判别器	71.42%	70.84%
仿真信号 数据增强	1DCNN-FZ	72.41%	70.63%
	2DCNN-FZ	67.25%	68.97%
UWACS-GAN 数据增强	1DCNN-DA	77.13%	76.47%
	2DCNN-DA	73.17%	73.01%
仿真信号识别 模型迁移	1DCNN-TL	81.17%	81.44%
	2DCNN-TL	89.17%	86.71%
生成信号识别 模型迁移	1DCNN-GTL	83.92%	84.22%
	2DCNN-GTL	<b>91.42%</b>	<b>91.55%</b>
数据量充足	1DCNN	84.43%	84.26%
	2DCNN	92.19%	92.20%




图 4.13 水声通信信号类间识别算法综合评价指标对比

结果表明,在水声通信信号数据量不足条件下,本文提出的基于数据增强的水声通信信号识别算法以及基于迁移学习的水声通信信号识别算法可以有效提高四类水声通信信号类间识别效果,甚至接近数据量充足条件下的识别效果;基于生成信号识别模型迁移的 1DCNN-GTL 模型的识别准确率与数据量充足条件下的 1DCNN 模型相比仅低 0.51 个百分点,宏 F1 值甚至仅低 0.04 个百分点;基于生成信号识别模型迁移的 2DCNN-GTL 模型的识别准确率和宏 F1 值与数据量充足条件下的 2DCNN 模型相比仅低不到 1 个百分点,是所有模型中识别效果最好的;UWACS-GAN 的判别器模型的识别准确率接近 1DCNN-FZ 模型的识别准确率,宏 F1 值高于 1DCNN-FZ 模型,识别准确率与宏 F1 值均高于 2DCNN-FZ 模型;基于时序信号数据增强识别模型的识别效果优于基于时频特征的数据增强识别模型,基于时序信号的迁移学习识别模型识别效果均比基于时频特征的迁移学习识别模型差;基于 UWACS-GAN 生成信号的相关模型识别效果优于基于仿真信号的相关模型,这是因为仿真信号是基于 BELLHOP 仿真信道以及窄带高斯白噪声生成的,而 BELLHOP 仿真信道是根据试验场景设置相关参数建立的一个物理模型,与实际情况存在不可避免的差异,实际条件下水下声场环境会影响声线的到达结构并且实际环境并不一定是白噪声环境,相比之下 UWACS-GAN 生成信号是基于实测水声通信信号生成的,携带了更符合实际水下声场的特征信息;基于迁移学习的水声通信信号类间识别相关算法识别效果要优于基于数据增强的水声通信信号类间识别相关算法,2DCNN-TL 模型和 2DCNN-GTL 模型的识别效果甚至优于数据量充足条件下的 1DCNN 模型。



#### 4.4.2 水声通信 MPSK 信号类内识别算法综合对比

在水声通信信号数据量不足条件下,将本文提出的水声通信 MPSK 信号类内识别模型识别结果的准确率和宏 F1 值统计,结果如表 4.6 所示。综合评价指标对比如图 4.14 所示,其中,图 4.14(a)为基于时序信号的水声通信 MPSK 信号类内识别 1DCNN 相关模型综合评价指标对比,图 4.14(b)为基于时频特征的水声通信 MPSK 信号类内识别 2DCNN 相关模型综合评价指标对比。

表 4.6 不同条件下水声通信 MPSK 信号类内识别模型综合评价指标对比

条件	模型	准确率	宏 F1 值
数据量不足	1DCNN-S	36.67%	36.41%
	2DCNN-S	46.33%	46.35%
UWACS-GAN	判别器	37.00%	36.83%
仿真信号 数据增强	1DCNN-FZ	37.67%	36.87%
	2DCNN-FZ	82.67%	82.62%
UWACS-GAN 数据增强	1DCNN-DA	38.33%	38.27%
	2DCNN-DA	84.67%	84.70%
仿真信号识别 模型迁移	1DCNN-TL	38.00%	37.72%
	2DCNN-TL	85.67%	85.72%
生成信号识别 模型迁移	1DCNN-GTL	42.33%	41.78%
	2DCNN-GTL	<b>86.00%</b>	<b>85.84%</b>
数据量充足	1DCNN	49.11%	49.23%
	2DCNN	89.89%	89.90%

结果表明,在水声通信信号数据量不足条件下,本文提出的基于数据增强的水声通信信号识别算法以及基于迁移学习的水声通信信号识别算法可以有效提高基于时频特征的水声通信 MPSK 信号类内识别效果,甚至接近数据量充足条件下的识别效果;基于时序信号的水声通信 MPSK 信号识别相关模型仍然识别失败;与数据量充足条件下的 2DCNN 模型相比,基于 UWACS-GAN 生成信号识别模型迁移的 2DCNN-GTL 模型识别效果差距最小,识别准确率和宏 F1 值仅低 4.0 个百分点左右,基于仿真信号识别模型迁移的 2DCNN-TL 模型次之,识别准确率和宏 F1 值低 4.2 个百分点左右,基于 UWACS-GAN 生成信号数据增强的 2DCNN-DA 模型再次之,识别准确率和宏 F1 值低 5.2 个百分点左右,基于仿真信号数据增强的 2DCNN-FZ 模型识别效果差距最大,识别准确率和

宏 F1 值低 7.2 个百分点左右。




图 4.14 水声通信 MPSK 信号类内识别算法综合评价指标对比

本文提出的基于数据增强的水声通信信号识别算法以及基于迁移学习的水声通信信号识别算法可以有效提高数据量不足条件下的水声通信信号识别效果。对于 MPSK、OFDM、DSSS 和 MFSK 信号的识别,最优模型为基于 UWACS-GAN 生成信号识别模型迁移的 2DCNN-GTL 模型;对于 BPSK、QPSK 和 8PSK 信号的类内识别,最优模型为基于 UWACS-GAN 生成 MPSK 信号识别模型迁移的 2DCNN-GTL 模型。

#### 4.4.3 数据量不足条件下水声通信信号识别方案

在水声通信信号数据量不足条件下,本文根据不同水声通信信号识别目的提出了基于数据增强的水声通信信号识别算法以及基于迁移学习的水声通信信号识别算法,提高了水声通信信号识别效果,最终达到接近水声通信信号数据量充足条件下的识别效果,说明本文设计的算法具有实际应用价值。

本节对以上算法进行归纳总结,得到水声通信信号数据量不足条件下最优的水声通信信号识别方案,如图 4.15 所示。其中, MPSK、OFDM、DSSS 和 MFSK 信号类间识别采用基于 UWACS-GAN 生成信号识别模型迁移的 2DCNN-GTL 模型对输入信号的时频特征进行识别;识别出的 MPSK 信号类内识别采用基于 UWACS-GAN 生成 MPSK 信号识别模型迁移的 2DCNN-GTL 模型对其时频特征进行识别;识别出的 MFSK 信号类内识别采用基于循环谱特征的 2DCNN-S 模型对其循环谱特征进行识别。

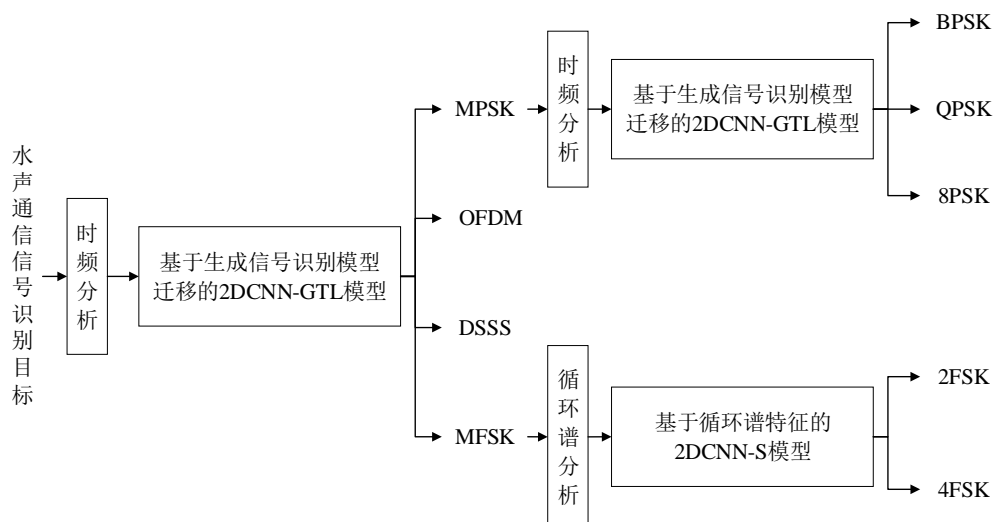


图 4.15 数据量不足条件下水声通信信号识别方案

## 4.5 本章小结

本章研究了基于迁移学习的水声通信信号识别技术，并总结了在数据量不足条件下的水声通信信号识别方案。

首先，本章介绍了基于卷积神经网络的迁移学习方法和相关策略，并设计了基于卷积神经网络的水声通信信号识别迁移学习方案。

然后，本章分别从仿真信号识别模型和 UWACS-GAN 生成信号识别模型进行基于迁移学习的水声通信信号识别试验。试验结果显示，基于迁移学习的水声通信信号识别算法可以有效提高数据量不足条件下水声通信信号识别效果；无论在四类水声通信信号类间识别或 MPSK 信号类内识别，基于 UWACS-GAN 生成信号识别模型迁移的水声通信信号识别算法要优于基于仿真信号识别模型迁移的水声通信信号识别算法。

最后，本章对本文在水声通信信号数据量不足条件下提出的算法进行了对比分析，并提出了最终的水声通信信号识别方案。方案采用基于 UWACS-GAN 生成信号识别模型的 2DCNN-GTL 模型作为 MPSK、OFDM、DSSS 和 MFSK 信号类间识别模型，基于 UWACS-GAN 生成 MPSK 信号识别模型的 2DCNN-GTL 模型作为 BPSK、QPSK 和 8PSK 信号的类内识别模型；将基于循环谱特征的 2DCNN-S 模型作为 2FSK 和 4FSK 信号的类内识别模型。

## 结 论

本文主要研究基于数据增强及迁移学习的水声通信信号识别技术,以提高水声通信信号数据量不足条件下,基于卷积神经网络的水声通信信号识别方法的识别效果。本文设计了水声通信信号生成对抗网络(UWACS-GAN)对松花湖实测水声通信信号进行数据增强研究,并基于 UWACS-GAN 生成信号识别模型进行迁移学习,试验结果表明了方法的有效性和实用性。

本文主要研究工作总结如下:

1.针对四类常用水声通信信号及其特征,研究基于卷积神经网络的水声通信信号识别技术。设计水声通信信号类间识别与 MPSK 信号以及 MFSK 信号类内识别相结合的水声通信信号识别方案,并通过仿真实验和松花湖试验进行应用分析。仿真实验结果表明,本文设计的基于卷积神经网络的水声通信信号识别算法能够实现水声通信信号类间识别,以及 MPSK 信号和 MFSK 信号的类内识别,并且具有良好的抗噪性。试验结果表明,在数据量充足条件下,本文设计的基于卷积神经网络的水声通信信号识别算法能够实现水声通信信号类间和类内识别;但在数据量不足条件下,无法实现对四类水声通信信号的类间识别以及对 MPSK 信号的类内识别,只有基于循环谱特征的 2DCNN-S 模型能准确识别 2FSK 和 4FSK 信号。

2.引入数据增强技术,实现在数据量不足条件下对水声通信信号的识别。首先提出了基于生成对抗网络的水声通信信号数据增强方案,然后基于该方案设计了水声通信信号生成对抗网络(UWACS-GAN)数据增强模型并对水声通信信号数据集进行数据增强,并与仿真信号数据增强效果对比分析。试验结果表明,在数据量不足条件下,基于数据增强的水声通信信号识别技术可以有效提高水声通信信号识别效果;基于 UWACS-GAN 生成信号增强的 1DCNN-DA 模型和 2DCNN-DA 模型的识别效果优于基于仿真信号增强的 1DCNN-FZ 模型和 2DCNN-FZ 模型;对于四类水声通信信号类间识别,基于时序信号的 1DCNN-DA 模型和 1DCNN-FZ 模型识别效果优于基于时频特征的 2DCNN-DA 模型和 2DCNN-FZ 模型;对于 MPSK 信号类内识别,基于 UWACS-GAN 生成信号增强的 2DCNN-DA 模型识别效果优于基于仿真信号增强的 2DCNN-FZ 模型。

3.为进一步提升在水声通信信号数据量不足条件下的水声通信信号识别效果,引入迁移学习。首先介绍了基于卷积神经网络模型的迁移学习方法和策略,然后设计了基于卷积神经网络的水声通信信号识别迁移学习方案并开展试验研究,最后总结了水声通信

信号识别方案。试验结果显示,在水声通信信号数据量不足条件下,基于卷积神经网络模型的迁移学习可以有效提高水声通信信号识别效果;基于 UWACS-GAN 生成信号识别模型迁移学习的水声通信信号识别效果要优于基于仿真信号识别模型迁移学习的水声通信信号识别效果;对于四类水声通信信号类间识别,基于 UWACS-GAN 生成信号识别模型迁移的 1DCNN-GTL 模型和 2DCNN-GTL 模型的识别准确率分别为 83.92%和 91.42%,仅比数据量充足条件下的 1DCNN 模型(84.43%)和 2DCNN 模型(92.19%)低不到 1 个百分点;基于时频特征的 2DCNN-GTL 模型和 2DCNN-TL 模型识别准确率高干数据量充足条件下的 1DCNN 模型;对于 MPSK 信号类内识别,基于 UWACS-GAN 生成信号识别模型的 2DCNN-GTL 模型的识别准确率为 86.00%,仅比数据量充足条件下的 2DCNN 模型(89.89%)低 3.89 个百分点。综合所有研究结果,最终设计的水声通信信号识别方案采用基于 UWACS-GAN 生成信号识别模型迁移的 2DCNN-GTL 模型实现四类水声通信信号类间识别,采用基于 UWACS-GAN 生成 MPSK 信号识别模型迁移的 2DCNN-GTL 模型实现 MPSK 信号类内识别,采用基于循环谱特征的 2DCNN-S 模型实现 MFSK 信号类内识别。

在水声通信信号数据量不足条件下,本文提出的算法可以有效提高以卷积神经网络为代表的机器学习算法的识别效果,具有实际应用的价值。本文基于仿真和试验研究是对机器学习在水声领域应用中的初步探索,依然存在亟待解决的问题,对进一步工作展望如下:

(1)本文研究的水声通信信号识别背景为单一水域,对多水域之间的迁移学习是未来研究的重点;

(2)本文所研究的算法不仅可以应用于水声通信信号识别领域,水下目标识别、水下目标定位等领域同样适用。

## 参考文献

- [1] Liles S, Dietz J E, Rogers M, et al. Applying traditional military principles to cyber warfare[C]//2012 4th International Conference on Cyber Conflict (CYCON 2012). IEEE, 2012: 1-12.
- [2] Cebrowski A K, Garstka J J. Network-centric warfare: Its origin and future[C]//US Naval Institute Proceedings. 1998, 124(1): 28-35.
- [3] 徐文,鄢社锋,季飞,陈景东,张杰,赵航芳,陈戈,吴永清,余华,张歆,许肖梅,陈惠芳.海洋信息获取、传输、处理及融合前沿研究评述[J].中国科学:信息科学,2016,46(08):1053-1085.
- [4] 周志华.机器学习[M].清华大学出版社,2016:1-52.
- [5] Bianco M J, Gerstoft P, Traer J, et al. Machine learning in acoustics: Theory and applications[J]. The Journal of the Acoustical Society of America, 2019, 146(5): 3590-3628.
- [6] Niu H, Reeves E, Gerstoft P. Source localization in an ocean waveguide using supervised machine learning[J]. The Journal of the Acoustical Society of America, 2017.
- [7] Huang Z, Xu J, Gong Z, et al. Source localization using deep neural networks in a shallow water environment[J]. Journal of the Acoustical Society of America, 2018,143(5):2922-2932.
- [8] Niu H, Gong Z, Ozanich E, et al. Deep-learning source localization using multi-frequency magnitude-only data[J]. The Journal of the Acoustical Society of America, 2019.
- [9] Liu Y, Niu H, Li Z. A multi-task learning convolutional neural network for source localization in deep ocean[J]. The Journal of the Acoustical Society of America, 2020, 148(2): 873-883.
- [10] Wang W, Wang Z, Su L, et al. Source depth estimation using spectral transformations and convolutional neural network in a deep-sea environment[J]. The Journal of the Acoustical Society of America, 2020, 148(6): 3633-3644.
- [11] 王强,曾向阳.深度学习方法及其在水下目标识别中的应用[C].中国声学学会水声学分会.中国声学学会水声学分会 2015 年学术会议论文集.中国声学学会水声学分会:中国声学学会,2015:148-150.

- [12] Kim J, Cho H, Pyo J, et al. The convolution neural network based agent vehicle detection using forward-looking sonar image[C]//OCEANS 2016 MTS/IEEE Monterey. IEEE, 2016: 1-5.
- [13] Valdenegro-Toro M. Best practices in convolutional networks for forward-looking sonar image recognition[C]//OCEANS 2017-Aberdeen. IEEE, 2017: 1-9.
- [14] 王昆明.基于迁移学习的水下目标识别方法研究[D].哈尔滨工程大学,2018.
- [15] 刘韦伯.基于深度学习的水下目标图像识别方法研究[D].电子科技大学,2019.
- [16] 王升贵,胡桥,陈迎亮,叶明刚.基于深度学习的水下目标识别方法研究[J].舰船科学技术,2020,42(23):141-145.
- [17] 刘有用,张江梅,王坤朋,冯兴华,杨秀洪.不平衡数据集下的水下目标快速识别方法[J].计算机工程与应用,2020,v.56;No.960(17):236-242.
- [18] Piccolo J, Haramuniz G, Michalopoulou Z H. Geoacoustic inversion with generalized additive models[J]. The Journal of the Acoustical Society of America, 2019, 145(6): EL463-EL468.
- [19] Frederick C, Villar S, Michalopoulou Z H. Seabed classification using physics-based modeling and machine learning[J]. The Journal of the Acoustical Society of America, 2020, 148(2): 859-872.
- [20] Smaragdakis C, Taroudakis M I. Acoustic signal characterization based on hidden Markov models with applications to geoacoustic inversions[J]. The Journal of the Acoustical Society of America, 2020, 148(4): 2337-2350.
- [21] Shen Y, Pan X, Zheng Z, et al. Matched-field geoacoustic inversion based on radial basis function neural network[J]. The Journal of the Acoustical Society of America, 2020, 148(5): 3279-3290.
- [22] de Sousa M A A, Pires R, Del-Moral-Hernandez E. OFDM symbol identification by an unsupervised learning system under dynamically changing channel effects[J]. Neural Computing and Applications, 2018, 30(12): 3759-3771.
- [23] Jiang R, Wang X, Cao S, et al. Deep neural networks for channel estimation in underwater acoustic OFDM systems[J]. IEEE access, 2019, 7: 23579-23594.
- [24] Zhang Y, Wang H, Li C, et al. Meta-learning-aided orthogonal frequency division multiplexing for underwater acoustic communications[J]. The Journal of the Acoustical Society of America, 2021, 149(6): 4596-4606.

- [25] Lee-Leon A, Yuen C, Herremans D. Underwater Acoustic Communication Receiver Using Deep Belief Network[J]. IEEE Transactions on Communications, 2021, 69(6): 3698-3708.
- [26] Ouyang D, Li Y, Wang Z. Channel Estimation for Underwater Acoustic OFDM Communications: An Image Super-Resolution Approach[J]. arXiv preprint arXiv:2103.04345, 2021.
- [27] Zhang Y, Li C, Wang H, et al. Deep learning aided OFDM receiver for underwater acoustic communications[J]. Applied Acoustics, 2022, 187: 108515.
- [28] Wang C, Wang Z, Sun W, et al. Reinforcement learning-based adaptive transmission in time-varying underwater acoustic channels[J]. IEEE access, 2017, 6: 2541-2558.
- [29] Fu Q, Song A. Adaptive modulation for underwater acoustic communications based on reinforcement learning[C]//OCEANS 2018 MTS/IEEE Charleston. IEEE, 2018: 1-8.
- [30] Su W, Lin J, Chen K, et al. Reinforcement learning-based adaptive modulation and coding for efficient underwater communications[J]. IEEE access, 2019, 7: 67539-67550.
- [31] Harb H, Makhoul A, Couturier R. An enhanced K-means and ANOVA-based clustering approach for similarity aggregation in underwater wireless sensor networks[J]. IEEE Sensors Journal, 2015, 15(10): 5483-5493.
- [32] Park S H, Mitchell P D, Grace D. Reinforcement learning based MAC protocol (UW-ALOHA-QM) for mobile underwater acoustic sensor networks[J]. IEEE Access, 2020, 9: 5906-5919.
- [33] Zhou S, Wang Z. OFDM for underwater acoustic communications[M]. John Wiley & Sons, 2014.
- [34] 韩笑.浅海环境下单载波时域均衡水声通信关键技术研究[D].哈尔滨工程大学,2016.
- [35] O. A. Dobre, A. Abdi, Y. Bar-Ness, and W. Su, "Survey of automatic modulation classification techniques: classical approaches and new trends," IET Communications, vol. 1, no. 2, pp. 137–156, 2007.
- [36] Wang L, Guo S, Jia C. Recognition of digital modulation signals based on wavelet amplitude difference[C]. IEEE International Conference on Software Engineering & Service Science, 2017.
- [37] Li S, Wang Y. Method of modulation recognition of typical communication satellite signals based on cyclostationary[C]. Complex Medical Engineering (CME), IEEE, 2013.
- [38] 江伟华,曹秀岭,童峰.采用支持向量机的水声通信信号调制识别方法[J].厦门大学学



- 报:自然科学版,2015(54):539.
- [39] 葛轶洲,叶蓁,周青,等. Alpha 稳定分布噪声下的水下通信调制识别[J]. 通信对抗, 2016(2):16-19.
- [40] Li-Da D, Shi-Lian W, Wei Z. Modulation classification of underwater acoustic communication signals based on deep learning[C]//2018 OCEANS-MTS/IEEE Kobe Techno-Oceans (OTO). IEEE, 2018: 1-4.
- [41] 邵梦琦. 水声通信信号调制模式识别算法研究[D]. 哈尔滨工程大学, 2019.
- [42] Yu X, Li L, Yin J, et al. Modulation pattern recognition of non-cooperative underwater acoustic communication signals based on LSTM network[C]//2019 IEEE International Conference on Signal, Information and Data Processing (ICSIDP). IEEE, 2019: 1-5.
- [43] 华迪. 基于生成式对抗网络的数据增强技术研究[D]. 哈尔滨工业大学, 2020.
- [44] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [45] Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.
- [46] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv:1511.06434, 2015.
- [47] Odena A, Olah C, Shlens J. Conditional image synthesis with auxiliary classifier gans[C]//International conference on machine learning. PMLR, 2017: 2642-2651.
- [48] Larsen A B L, Sønderby S K, Larochelle H, et al. Autoencoding beyond pixels using a learned similarity metric[C]//International conference on machine learning. PMLR, 2016: 1558-1566.
- [49] Zhang H, Xu T, Li H, et al. StackGAN: Text to Photo-realistic Image Synthesis with Stacked Generative Adversarial Networks[J]. 2017 IEEE International Conference on Computer Vision (ICCV), 2017.
- [50] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International conference on machine learning. PMLR, 2017: 214-223.
- [51] Zhu J Y, Park T, Isola P, et al. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks[J]. IEEE, 2017.
- [52] Isola P, Zhu J Y, Zhou T, et al. Image-to-Image Translation with Conditional Adversarial Networks[J]. IEEE Conference on Computer Vision & Pattern Recognition, 2016.

- [53] Wang C , Xu C , Wanga C , et al. Perceptual Adversarial Networks for Image-to-Image Transformation[J]. IEEE Transactions on Image Processing, 2018:4066-4079.
- [54] Tang B, Tu Y, Zhang Z, et al. Digital signal modulation classification with data augmentation using generative adversarial nets in cognitive radio networks[J]. IEEE Access, 2018, 6: 15713-15722.
- [55] 姚晓辉,杨宏晖,李益青.基于生成对抗网络的水声通信信号特征提取方法[A].中国声学学会水声学分会.中国声学学会水声学分会 2019 年学术会议论文集[C].中国声学学会水声学分会:《声学技术》编辑部,2019:3.
- [56] Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on knowledge and data engineering, 2009, 22(10): 1345-1359.
- [57] Tan C, Sun F, Kong T, et al. A survey on deep transfer learning[C]//International conference on artificial neural networks. Springer, Cham, 2018: 270-279.
- [58] Tsai Y H H, Yeh Y R, Wang Y C F. Learning cross-domain landmarks for heterogeneous domain adaptation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 5081-5090.
- [59] Tzeng E, Hoffman J, Zhang N, et al. Deep domain confusion: Maximizing for domain invariance[J]. arXiv preprint arXiv:1412.3474, 2014.
- [60] Tzeng E, Hoffman J, Saenko K, et al. Adversarial discriminative domain adaptation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7167-7176.
- [61] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [62] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//European conference on computer vision. Springer, Cham, 2014: 818-833.
- [63] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [64] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [65] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

- [66] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [67] Gao L, Zhang X, Gao J, et al. Fusion image based radar signal feature extraction and modulation recognition[J]. IEEE Access, 2019, 7: 13135-13148.
- [68] Bu K, He Y, Jing X, et al. Adversarial transfer learning for deep learning based automatic modulation classification[J]. IEEE Signal Processing Letters, 2020, 27: 880-884.
- [69] Xiao Y, Liu W, Gao L. Radar signal recognition based on transfer learning and feature fusion[J]. Mobile Networks and Applications, 2020, 25(4): 1563-1571.
- [70] 沈再阳. MATLAB 信号处理 [M]. 清华大学出版社, 2017: 310-320.
- [71] Lilly J M, Olhede S C. Generalized Morse wavelets as a superfamily of analytic wavelets[J]. IEEE Transactions on Signal Processing, 2012, 60(11): 6036-6041.
- [72] 黄知涛, 周一宇, 姜文利. 循环平稳信号处理与应用[M]. 2006: 23-35.
- [73] 李静. 基于循环谱相关的通信信号调制方式识别[D]. 燕山大学, 2010.
- [74] Hao S, Ge F X, Li Y, et al. Multisensor bearing fault diagnosis based on one-dimensional convolutional long short-term memory networks[J]. Measurement, 2020, 159: 107802.